골든 데이터셋은 어떻게 생겼고, 왜 그렇게 나눴는가

보고서 1의 검색 · 생성 · 근거 충실도 · 최종 답변 평가에 쓰는 골든 데이터셋을 정리했습니다. 골든 질문을 어떻게 만들었는지, dev와 test에 어떻게 나눴고 무엇이 들어 있는지, 왜 두 쪽의 문서를 겹치지 않게 했는지, 이 자의 눈금이 어디까지 믿을 만한지를 순서대로 다룹니다.

2026-10-19 · 골든 분할: `eval/golden/` (final6) · 코드 · 측정 문서 기준: `rfg_rag` `03ace46`

용어 — train은 없습니다 저장소의 분할 이름은 `dev` 와 `test` 입니다. RAG는 모델을 학습시키지 않으므로 학습용 'train' 세트가 없습니다. **dev**는 설정을 고칠 때마다 돌리는 조절용, **test**는 설정을 고정한 뒤 한 번만 돌리는 최종 점수용입니다. 발표에서도 이 두 이름을 쓰는 것을 권합니다.

먼저 알아야 할 네 가지

1 질문은 LLM이 만들고, 별도 호출로 검증했습니다

후보 5,967개 중 독립 검증과 쓸모 판정을 통과한 1,351개(22.6%)만 출시했습니다. 사람 검토는 두지 않았고, 비용은 $47.64(문항당 $0.035)입니다.

2 문서 단위로 dev 30% · test 70%

dev 30문서 · 408문항, test 68문서 · 943문항. 두 쪽에 같은 문서는 하나도 없고, 98개 문서 전부가 어느 한쪽에 들어갑니다. 최종 평가는 핵심 사실을 뽑을 수 있는 dev 384 · test 880문항으로 채점했습니다.

3 두 쪽의 모양은 거의 같습니다

주제 · 난이도 · 근거 수의 구성비는 dev와 test에서 비슷하며, 항목별 차이는 최대 약 1.3%p입니다. 문서째 옮기면서도 주제 × 난이도 칸마다 dev 몫을 30%에 가깝게 맞췄기 때문입니다.

4 문서를 겹치지 않게 한 이유는 누수

dev에서 특정 문서에 맞춰 고친 것이 test 점수를 부풀리지 않게 하려는 것입니다. test 점수가 '처음 보는 RFP'에서의 성능에 가까워집니다.

① 만들기
생성 · 주제별 프롬프트 · 검증

② 나누기
dev · test 분포

③ 숫자로 보기
두 분할 비교표

④ 겹치지 않게
누수와 분할 방법

⑤ 자의 눈금
라벨 연결 · 제외율

⑥ 쓰는 법
dev 조절 · test 1회

부록 A · B
dev 30 · test 68 문서

부록 C
출처

① 골든 데이터는 어떻게 만들었나

문서 근거에서 질문 · 답 · 근거를 만들고, 별도 검증 호출을 통과한 것만 남깁니다. 생성과 검증에는 같은 gpt-5-mini를 썼습니다.

1. 근거 묶음 고르기
v11 청크에서 주제에 맞는 청크 묶음을 계획

→

2. 후보 생성
주제 일곱 가지마다 전용 프롬프트로 gpt-5-mini가 질문 · 답 · 근거 · 핵심 사실

→

3. 독립 검증
무료 규칙 · 중복 검사 뒤, 검증기가 생성 답을 받지 않고 질문과 근거만으로 답을 다시 만들어 대조 (추론 강도 high)

→

4. 출시 판정
RFP를 읽는 사람이 물을 만한 질문인가 (목차 · 쪽 번호 · 연락처 질문 제거)



주제 일곱 가지 — 실패 모양마다 하나씩

주제	질문 모양	무엇을 시험하나	출시
수치 numeric	금액 · 기간 · 수량 하나를 묻기	숫자를 정확히 찾고 옮기는가	338
표 table	표의 행 · 열 값을 묻기 (머리글 행 포함)	표 파싱 · 청킹이 값을 살렸는가	321
조건 condition	자격 · 제출 조건을 묻기	조건 문장을 빠짐없이 옮기는가	236
다중 근거 multi_hop	청크 둘 이상을 이어야 답하기	근거를 모두 찾아 문맥에 담는가	247
비교 comparison	같은 종류의 두 값을 견주기	두 근거를 함께 가져오는가	184
답 없음 unanswerable	문서에 없는 내용 — "없다"가 정답	모르는 것을 지어내지 않는가	16
틀린 전제 false_premise	틀린 사실을 깔고 묻기	전제를 바로잡는가	9

답 없음 · 틀린 전제는 합쳐 25문항뿐이라, 두 주제의 점수는 반드시 문항 수와 함께 읽어야 합니다.

비용 — 품질을 사는 곳에 썼습니다

단계 (gpt-5-mini, 실행 기록 합산)	USD	비중
후보 생성	13.31	28%
독립 검증 (추론 강도 high)	29.11	61% — 틀린 정답이 자에 들어가지 않게 하는 곳
출시 쓸모 판정	5.22	11%
합계 · 출시 문항당	**47.64**	**$0.035 / 문항**

유료 명령은 모델 · 추론 강도 · 단가 · 최대 호출 수 · 총예산을 모두 받아야 시작하며 기본값이 없습니다. 실험 명령은 호출 전 최악 비용을 장부에 잡아 상한을 넘으면 보내지 않습니다.

사람 검토 대신 자동 검증을 둔 이유

하는 것

- 떨어진 후보는 버리지 않고 **실패 기록**으로 남깁니다.
- 실패 기록으로 예방 규칙을 만들되, 별도 측정에서 도움이 된다고 확인한 규칙만 채택하도록 구현했습니다(RRSI 채택 하한, `golden_pipeline/adoption.py`).
- 빈 칸(주제 · 난이도)은 사람이 채우지 않고 재생성으로 채웁니다.

왜

- 1,351문항을 사람이 검토하면 기준이 사람마다 달라지고 시간이 듭니다.
- 검증 규칙이 코드로 있으면, 질문을 더 만들 때도 같은 기준이 그대로 적용됩니다.

생성 방식 비교 — A · B · C

같은 근거 묶음 42개(주제당 6개)에 세 방식을 돌려 같은 검증기로 견줬습니다.

방식	내용	첫 시도 통과	메모
A	주제 전용 프롬프트 + 자기 개선 loop	21/42	첫 시도 유효 질문당 $0.012. 최초 시도를 포함해 최대 3라운드 후 누적 30/42, 전체 유효 질문당 $0.026
B	고정 프롬프트	14/42	유효 질문당 $0.014
C	사람이 웹의 gpt 6 pro에 요청해 생성	20/42	모델 · 인터페이스 차이가 함께 섞임

A의 첫 시도는 21/42, C는 20/42였습니다. A는 최초 시도 뒤 최대 두 차례 더 시도해 누적 30/42를 확보했지만, 예방 규칙은 어느 주제에서도 채택되지 않아 자기 개선 효과는 입증하지 못했습니다. 30/42는 개선이 아니라 재시도로 얻은 수확입니다. 실험 비용은 A $0.79 · B $0.20 · C 검증 $0.23입니다.

주제별 프롬프트 — A는 주제마다 따로 썼습니다

출시한 dev 408 · test 943문항은 모두 A 방식으로 만들었고, A는 주제마다 다른 프롬프트 파일 `golden_pipeline/prompts/A/{주제}.txt` (16~25줄)을 씁니다. B는 일곱 주제가 10줄짜리 `B.txt` 하나를 같이 씁니다. 두 방식 모두 같은 주제 설명(`$requires`)과 structure 필드(`$structure`)를 받으므로, 둘의 차이는 **A 파일에만 있는 주제 전용 규칙**입니다 (`generation.py:58`). '보이는 근거'는 생성기 한 번에 보여 주는 근거 수(`bundle_units`)입니다.

A 프롬프트 공통 (답 없음을 뺀 여섯 주제)

> 사용자 메시지의 근거([E1], [E2] …)에 적힌 내용만 쓴다. 근거에 없는 사실을 더하지 않는다.
>
> 질문에 발주 기관 · 사업 이름을 쓰지 않는다. 문서 이름은 프로그램이 나중에 질문 앞에 붙이니, 질문은 묻는 내용으로 바로 시작한다.
>
> evidence 에는 답에 실제로 쓴 근거 라벨만 넣는다.
>
> 출력은 아래 JSON 객체 하나뿐이다. 다른 글은 쓰지 않는다.

B 고정 프롬프트 — 규칙 부분 전부

> 주제: $topic / 요구 구조: $requires
>
> 사용자 메시지의 근거([E1], [E2] …)만 보고 질문 하나와 정답을 만든다.
>
> 질문에 발주 기관 · 사업 이름을 쓰지 않는다. …
>
> 출력은 아래 JSON 객체 하나뿐이다. … structure 의 필드: $structure

A에만 있는 주제 전용 규칙 (원문 인용)

주제 · 보이는 근거	핵심 규칙	막으려는 실패
수치 numeric 근거 2개	질문은 값 하나를 묻는다. 답에는 그 값과 단위를 근거에 적힌 그대로 넣는다. 값 없이 설명만 하는 답, 범위나 경향만 말하는 답은 만들지 않는다. value 는 수만 쓴다 (예: 230,000). unit 은 그 수 바로 뒤에 붙은 단위만 쓴다 … "이내", "이상", "(부가세 포함)" 같은 말은 unit 에 넣지 않고 답 글에만 쓴다.	값 대신 설명을 답으로 삼기, 단위 칸에 꾸밈말이 섞여 문자열 대조가 깨지기
표 table 표 행 3개	행 이름과 열 이름을 모두 정해야 답이 하나로 정해지는 질문을 만든다. 라벨에 '머리글 행' 이 붙은 근거의 칸들이 열 이름이다. column 은 그 칸 중 첫 칸이 아닌 것을 쓴다. row 는 머리글 행이 아닌 표 행의 첫 칸을 쓴다. 머리글 행 자체를 묻지 않는다. answer 는 비우지 않는다.	열 이름을 지어내기, 머리글 행 자체를 묻기, 빈 답
조건 condition 근거 2개	조건이나 예외를 빼면 답이 틀리게 되는 질문을 만든다. 답에는 그 조건이나 예외를 함께 쓴다. structure 의 condition 은 근거에 적힌 문구 그대로 쓴다.	조건이 없어도 답이 같은 질문, 조건을 빼먹은 답
비교 comparison 근거 3개	대상 둘 이상을 견주어 그중 하나를 고르는 질문을 만든다 (어느 쪽이 더 큰가 · 많은가 · 이른가 등). … 값을 나란히 묻기만 하는 질문은 만들지 않는다. 값은 대상마다 따로 적힌 금액 · 기간 · 수량 · 날짜 · 비율 · 기준 같은 것이다. 대상 이름을 값으로 다시 쓰지 않는다. answer 는 … 대상마다 '이름 값' 을 ', ' 로 잇고 끝에 '. 답: 이름' 을 붙인다 (예: A안 1억원, B안 2억원. 답: B안).	고르지 않고 값만 늘어놓기, 대상 이름을 값으로 되풀이하기
다중 근거 multi_hop 근거 3개	한 근거에서 얻은 내용으로 다른 근거를 찾아야 답이 나오는 질문을 만든다. 근거 라벨 옆의 청크 번호가 다른 근거를 이어야 답이 나오게 묻고 … 같은 청크의 근거끼리만 이은 질문은 multi_hop 이 아니다. structure 는 필드가 없는 빈 객체 {} 그대로 둔다.	한 청크 안에서 끝나는 가짜 다중 근거, 빈 틀에 필드를 지어내기
답 없음 unanswerable 다른 사업 문서 근거 2개	근거([E1], [E2] …)는 질문할 사업과 다른 사업의 문서다. 그 사업에만 있을 만한 구체적인 속성 하나를 고른다 (예: 특정 장비의 사양 …). 예산 · 사업 기간 · 하자보수 · 보안 · 투입 인력 · 제출 서류처럼 어느 RFP 에나 있는 속성은 고르지 않는다. 답은 정확히 "제공된 문서에서 확인할 수 없습니다." 이다.	대상 문서에 실제로 있는 내용을 '없음'으로 만들기
틀린 전제 false_premise 근거 2개	근거에 적힌 금액 · 기간 · 개수 · 날짜 하나를 고른다. 이것이 actual 이다. actual 의 수만 바꾼 stated 를 만든다. … 흔한 값(1년, 12개월 등)을 피하고 자릿수 끝을 바꾼 값을 쓴다. 질문에 actual 을 쓰지 않는다. 답은 전제가 틀렸다고 밝히고 actual 을 근거에 적힌 그대로 쓴다.	바꾼 값이 문서 다른 곳에 실제로 있기, 질문에 정답이 새기

규칙이 만든 실제 dev 문항

주제마다 dev 문항 하나씩입니다. 질문 앞의 "○○기관의 「○○」 사업에서"는 프로그램이 붙인 부분이라 뺐습니다.

주제	질문	답 · structure
수치	사업비는 얼마인가?	157,300,000원(VAT 포함) value 157,300,000 · unit 원 — "(VAT 포함)"은 답 글에만
표	수행실적 행의 배점은 무엇인가?	6.0 row 수행실적 · column 배점
조건	평가가 서면평가로 대체되는 조건은 무엇인가?	응찰 업체가 5개 초과할 경우 및 코로나 상황에 따라 서면평가로 대체 가능
비교	어느 평가항목의 배점이 더 높은가?	기능 요구 사항 5, 데이터 요구 사항 4. 답: 기능 요구 사항
다중 근거	요구사항 고유번호 COR-003의 요구사항 분류는 무엇인가?	프로젝트 관리 요구사항 고유번호와 분류가 서로 다른 청크에 있음
답 없음	비교과 교육 참여 활동 문서에 '교무과 전자출결관리 모바일 앱 (교수용/학생용)'의 제공 여부 및 기능 명세가 포함되어 있습니까?	제공된 문서에서 확인할 수 없습니다. 속성은 다른 사업 문서에서 빌림
틀린 전제	공동수급체를 7개 이하로 구성해야 하는 것으로 이해하고 있는데, 맞습니까?	틀렸습니다. 공동수급체는 7개 이하가 아니라 5개 이하로 구성하여야 합니다. stated 7개 이하 · actual 5개 이하

순서대로 numeric-A-night1-r2-0012, table-A-fill4-r1-0205, condition-A-night1-r2-0097, comparison-A-fill1-r2-0038, multi_hop-A-span2-r1-0072, unanswerable-A-ap7-dev-r1-0012, false_premise-A-ap1-r1-0024

프롬프트를 고친 이력 — dev 문항은 어느 판에서 나왔나

각 문항에는 생성에 쓴 프롬프트 파일의 SHA-256이 `prompt_version`으로 남아 있습니다. 이를 git 이력의 각 판과 맞춰 dev 408문항이 어느 판에서 나왔는지 셌습니다.

주제	판(커밋) · dev 문항 수	그 판에서 더한 규칙
수치 104	`b2d96a4` 60 · `6a0c258` 44	6a0c258: value 는 수만, unit 은 수 바로 뒤 단위만
표 96	`b2d96a4` 8 · `05ffdef` 14 · `6cad562` 74	05ffdef: 머리글 행 라벨도 인용, 답을 비우지 않음 · 6cad562: '머리글 행' 표시와 row · column을 어디서 가져오는지
조건 69	`b2d96a4` 69	지금 파일과 같은 판
비교 56	`b2d96a4` 9 · `05ffdef` 5 · `bf07446` 42	05ffdef: 값은 대상 이름이 아닌 값 · bf07446: 하나를 고르는 질문만, 답 끝에 '답: 이름' 필수 · **ab430db**(같은 종류끼리만 견줌): dev 문항 0
다중 근거 71	`b2d96a4` 17 · `94c1036` 8 · `8223adf` 46	94c1036: structure {} · 8223adf: 청크 번호를 보이고 다른 청크를 이어야 함
답 없음 8 · 틀린 전제 4	`0e0b3c2` 8 · 4	두 주제를 처음 더한 판 그대로

비교 주제의 결함과 교체 "같은 종류끼리 견준다" 규칙(ab430db)보다 앞선 bf07446판 비교 문항 일부는 한 요구사항의 칸끼리 견줍니다. 예: comparison-A-fill3-r1-0019 "요구사항 분류와 응낙수준 중 어느 쪽이 '필수'인가?" → "답: 응낙수준". 이 꼴을 거르는 무료 규칙(`rule_reason` '칸 비교')이 출시 비교 184문항 중 **dev 13 · test 25, 모두 38문항**을 걸렀고, ab430db판으로 v12 근거에서 다시 만든 54문항(dev 15 · test 39, 사람 선별 없음)으로 채운 분할 **final7**(dev 410 · test 957)을 브랜치 `golden-comparison-fields` 에 만들었습니다. 비교 외 문항과 문서의 쪽은 그대로이며, 합쳐지기 전까지 이 보고서의 숫자는 final6 기준입니다.

② dev와 test는 어떻게 나뉘었나

문서 단위로 30 : 70. 두 쪽의 구성은 거의 같고, 크기와 쓰임만 다릅니다.

dev 조절용

408	30	29
문항	문서	기관

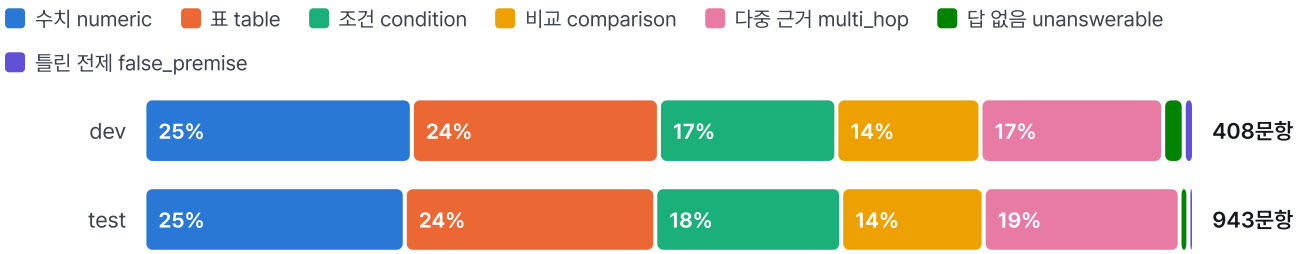
검색 · 생성 설정을 바꿀 때마다 돌립니다. 자주 돌리므로 작게 둡니다. 유료 확인은 30문항 표본으로 하다가, 설정을 정한 뒤 384문항 전체로 했습니다.

test 최종 1회

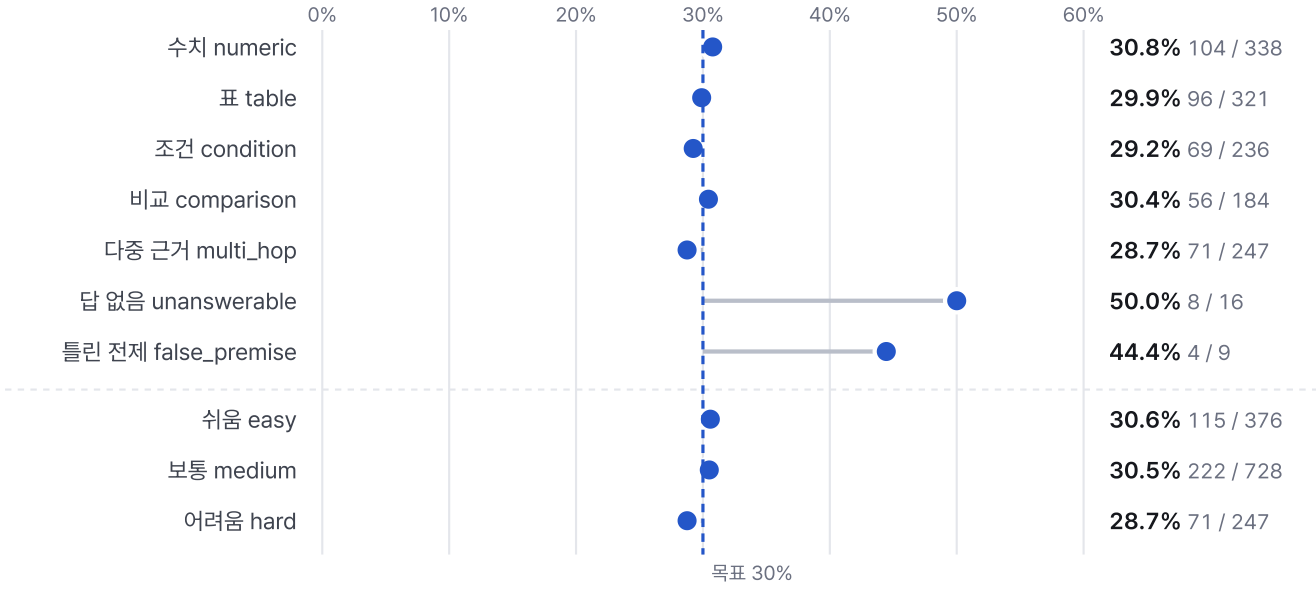
943	68	63
문항	문서	기관

설정을 고정한 뒤 한 번만 돌리는 최종 점수입니다. 2026-10-21에 880문항으로 한 번 돌렸고, 검색 · 생성 · 설정 선택에는 쓰지 않았습니다.

주제 구성 · 두 분할의 모양이 거의 같습니다



칸마다 dev가 가져간 몫 · 목표 30%. 문서째로 옮기므로 정확히 30%는 되지 않습니다



답 없음(16문항) · 틀린 전제(9문항)는 문항이 적어 문서 하나만 옮겨도 몫이 크게 흔들립니다. 나머지 다섯 주제와 세 난이도는 28.7~30.8%입니다.

③ 숫자로 본 두 분할

발표 슬라이드에 그대로 옮길 수 있는 표입니다. 모두 `eval/golden/` 파일에서 직접 집계했습니다.

항목	dev	test	읽는 법
문항	408	943	30.2% : 69.8%
질문 대상 문서	30	68	겹침 0 · 합계 98 = 코퍼스 전체
발주기관	29	63	7곳은 서로 다른 사업 문서로 양쪽에 (④)
문서 형식	HWP 29 · PDF 1	HWP 65 · PDF 3	코퍼스가 HWP 위주라 PDF는 양쪽 모두 소수
문서당 문항	8 · 12.5 · 26	7 · 14 · 22	최소 · 중앙값 · 최대
난이도 쉬움 · 보통 · 어려움	115 · 222 · 71	261 · 506 · 176	어려움은 모두 다중 근거(multi_hop)
근거 1 · 2 · 3 · 4개	176 · 164 · 60 · 8	409 · 389 · 128 · 17	비율 43 · 40 · 15 · 2% 대 43 · 41 · 14 · 2%
근거 항목 · 인용 문서	716 · 36	1,639 · 70	답 없음 질문이 다른 사업의 근거를 인용해 대상 문서보다 많음
질문 길이 (평균 글자)	83.8	84.0	질문 앞에 기관 · 사업명이 붙음
최종 평가 채점 문항	384	880	핵심 사실을 뽑을 수 없는 다중 근거 24 · 63문항 제외

주제별 문항

주제	dev	test	합계	dev 몫
수치 numeric	104	234	338	30.8%
표 table	96	225	321	29.9%
조건 condition	69	167	236	29.2%
다중 근거 multi_hop	71	176	247	28.7%
비교 comparison	56	128	184	30.4%
답 없음 unanswerable	8	8	16	50.0%
틀린 전제 false_premise	4	5	9	44.4%
합계	**408**	**943**	**1,351**	**30.2%**

④ 왜 dev와 test의 문서를 겹치지 않게 했나

dev에서 고친 것이 test 점수에 새어 들어가는 것을 막으려고 문서 단위로 나눴습니다.

문서가 겹치면 생기는 일 (예시)

1. dev에서 틀린 질문을 본다
"○○공단 사업의 하자보증 기간은?"을 못 찾음

→

2. 그 문서에 맞춰 고친다
그 문서의 별칭 · 사용자 사전 단어 · 라우팅 규칙을 추가

→

3. 같은 문서의 test 질문도 오른다
문서가 겹치면 test 점수가 실제 일반화보다 좋게 나옴

문서 단위로 나누면 dev에서 고친 것이 test의 다른 문서에는 직접 도움이 되지 않으므로, test 점수가 **처음 보는 RFP에서의 성능**에 가까워집니다. 질문 단위로 무작위로 나눴다면 같은 문서 · 같은 표에서 나온 질문이 양쪽에 섞여 이 누수가 생깁니다. 실제 서비스도 새로 올라온 RFP에 답해야 하므로, 이쪽이 쓰임에 맞는 시험입니다.

어떻게 나눴나

- 고정 시드(20261015)로 문서를 무작위로 고른 뒤, 주제 × 난이도 칸마다 dev 몫이 30%에 가까워지는 동안 문서를 하나씩 옮깁니다.
- 답 없음 질문은 근거가 다른 문서의 것이라 **질문이 묻는 문서**로 나눕니다.
- 나중에 주제를 더할 때도 기존 분할은 그대로 두고, 새 질문을 그 문서가 이미 간 쪽으로 보냅니다.
- 매니페스트에 개수 · 문서 수 · 파일 SHA-256을 남겨, 파일이 바뀌면 복원 단계에서 멈춥니다.

왜 30 : 70인가

- dev는 자주 돌리므로 작아야 하고, 그래도 주제마다 수십 문항은 남아야 합니다.
- test는 한 번만 돌리므로 크게 두어 최종 점수의 흔들림을 줄입니다.
- 최초 다섯 주제의 주제별 dev 몫은 28.7~30.8%입니다 (②). 주제 × 난이도 칸마다 이 범위가 보장되지는 않으며, 나중에 더한 답 없음 · 틀린 전제는 기존 문서 분할을 따릅니다.

남은 겹침과 한계

남은 것	내용	영향
기관 7곳	국민연금공단, 한국철도공사 등은 서로 다른 사업 문서로 양쪽에 있습니다.	기관 라우팅 규칙은 양쪽에 함께 작용합니다. 질문 대상 문서 자체는 겹치지 않지만, 서로 다른 RFP의 공통 요구사항 · 정형 문구는 양쪽에 남아 있습니다.
v11 청크 기반	골든은 v11 청크에서 만들었습니다.	청크 경계가 바뀌면 청크 라벨이 줄어듭니다(⑤).
dev의 크기	408문항을 주제 하나로 좁히면 수십 문항, 답 없음은 8문항입니다.	작은 주제의 차이는 우연일 수 있어, 문항 수와 함께 보고합니다.

⑤ 자의 눈금 — 청크 채점 범위는 입력마다 다릅니다

골든 근거를 청크에 연결해야 검색 점수를 셀 수 있습니다. 문서까지는 거의 다 연결되지만, 과거 파서 입력에서 청크 하나로 확정된 근거는 약 43%였습니다.

근거를 청크에 어떻게 연결하나

골든 근거 본문이 현재 청크 하나에 그대로 들어 있을 때만 청크 라벨을 붙입니다. 유사도 점수로 '비슷한' 청크를 고르지 않습니다 — 틀린 청크를 정답으로 삼으면 검색 점수가 거꾸로 나오기 때문입니다.

과거 파서 입력의 연결 품질 · 100문서 · 18,988청크, 2026-10-16

분할	문서 연결 (원본 SHA)	근거 항목의 문서 연결	유일 청크 연결	주요 실패 사유
dev	35/36 (97.2%)	692/716 (96.6%)	306/716 (42.7%)	20자 미만 290 · 미발견 64 · 모호 32
test	69/70 (98.6%)	1,620/1,639 (98.8%)	708/1,639 (43.2%)	20자 미만 674 · 미발견 188 · 모호 50

20자 미만	정규화 후 20자 미만. 짧은 수 · 코드 · 항목 이름만으로 청크를 확정하지 않으려는 고정 규칙이며, test 결과에 맞춰 조절하지 않았습니다.
미발견	근거 본문을 그대로 담은 현재 청크가 없음
모호	근거 본문을 그대로 담은 청크가 둘 이상

점수는 이렇게 읽습니다

청크 지표는 **각 근거 항목이 유일한 청크에 연결되고, 모든 근거 항목에 청크 라벨이 있는 질문만** 채점합니다(일부만 연결된 질문의 분모를 줄여 채점하지 않음). 다음은 위 표와 입력이 다른 별도 v12 입력(98문서 · 18,989청크)의 전체 dev 감사 결과입니다. 문서 지표 400문항, 청크 지표 194문항으로 청크 제외율이 51.5%입니다. 특히 표(97.9%) · 다중 근거(84.5%) · 비교(78.6%)가 많이 빠지므로, 청크 점수는 수치 · 조건 질문 쪽으로 기울어 있습니다. 최종 평가(보고서 3)는 커밋 `0d7fe39` 의 연결 규칙으로 같은 v12 입력에 라벨을 다시 붙여, 청크 지표를 답할 수 있는 dev 376문항 중 316문항, test 872문항 중 718문항으로 채점했습니다(제외율 16.0% · 17.7%).

발표 시 지킬 것 청크 점수를 말할 때는 항상 **채점 문항 수와 제외율**을 옆에 둡니다. 청킹을 바꾸면 03을 다시 실행해 라벨을 새로 붙이고, 연결률도 다시 냅니다.

⑥ dev와 test를 어떻게 쓰나

dev는 여러 번, test는 한 번. 순서를 지켜야 test 점수가 최종 점수로 남습니다.

dev 전체 · 검색만
검색 전용 재실행으로 설정 비교. API 0회

→

dev 안의 tuning / validation
가중치를 고르는 쪽과 확인하는 쪽을 다시 나눔

→

dev 유료 확인
30문항 표본 → 설정 확정 뒤 384문항, 견적 승인 후

→

test 880문항 · 1회
설정 고정 후 네 평가 한 번 · 2026-10-21 완료

단계	쓰는 데이터	무엇을 정하나	지킬 것
검색 설정 비교	dev 전체	임베딩 · BM25 · 가중치 · 후보 수	저장된 재작성 질문 재사용, 유료 호출 없음
가중치 고르기	dev의 tuning 203문항 / validation 205문항. 청크 지표는 각각 적격 99문항 / 95문항을 채점	tuning으로 고르고 validation으로 확인	validation을 보고 선택을 다시 바꾸지 않음
답변 품질 확인	dev 30문항 표본, 설정 확정 뒤 dev 384문항	근거 충실도 · 최종 정답의 수준	실행 전 견적 · 승인 (표본 약 $0.24 · 384문항 $2.61)
최종 점수	test 880문항	아무것도 정하지 않음 — 보고만 (정답률 83.7%)	한 번만, 결과를 보고 설정을 바꾸지 않음

test는 설정을 고정한 뒤 2026-10-21에 880문항으로 한 번 돌렸습니다. 확정한 설정은 보고서 1의 ⑤, 지표 전체는 보고서 3에 있습니다.

발표에서 받을 만한 질문

"LLM이 만든 질문을 믿을 수 있나?"	생성 답을 보지 않는 별도 검증 호출과 쓸모 판정을 통과한 22.6%만 썼고, 사람이 웹 모델에 요청한 C 방식과 첫 통과율이 비슷했습니다(①).
"왜 train이 없나?"	모델을 학습시키지 않는 RAG라서입니다. dev가 조절, test가 최종입니다.
"dev가 작지 않나?"	자주 돌리는 쪽이라 작게 두었고, 주제별 구성비는 test와 비슷합니다. 문항 수가 적은 주제는 점수와 함께 문항 수도 봅니다.
"같은 기관이 양쪽에 있는데?"	문서는 겹치지 않고, 기관 7곳만 다른 사업으로 양쪽에 있습니다(④).

부록 A · dev 문서 30개

질문이 묻는 문서 기준, 문항이 많은 순서. 기관은 `data/data_list.csv` 의 발주기관입니다.

#	발주기관	사업 (파일명 기준, 잘린 이름 포함)	형식	문항	주제별
1	서민금융진흥원	서민금융진흥원 서민금융 채팅 상담시스템 구축	HWP	26	수치 5 · 표 10 · 조건 3 · 비교 3 · 다중 근거 5
2	한국농어촌공사	아세안+3 식량안보정보시스템(AFSIS) 3단계 협력 (캄보디아	HWP	23	수치 5 · 표 5 · 조건 4 · 비교 4 · 다중 근거 5
3	한국철도공사	[재공고][긴급][협상형]운행정보기록 자동분석시스	HWP	20	수치 3 · 표 7 · 조건 4 · 비교 3 · 다중 근거 3
4	한국생산기술연구원	EIP3.0 고압가스 안전관리 시스템 구축 용역	HWP	19	수치 4 · 표 5 · 조건 3 · 비교 3 · 다중 근거 3 · 답 없음 1
5	서울특별시교육청	서울특별시교육청 지능정보화전략계획(ISP) 수립(2차)	HWP	18	수치 2 · 표 7 · 조건 2 · 비교 3 · 다중 근거 3 · 틀린 전제 1
6	한국연구재단	2024년 대학산학협력활동 실태조사 시스템(UICC) 기능개선	HWP	17	수치 4 · 표 3 · 조건 3 · 비교 3 · 다중 근거 4
7	한국어촌어항공단	한국어촌어항공단 경영관리시스템(ERP·GW) 기능 고도	HWP	16	수치 4 · 표 7 · 조건 1 · 비교 1 · 다중 근거 1 · 답 없음 1 · 틀린 전제 1
8	한국로봇산업진흥원	한국로봇산업진흥원 사업관리시스템 온라인평가	HWP	16	수치 4 · 표 2 · 조건 2 · 비교 1 · 다중 근거 7
9	을지대학교	을지대학교 비교과시스템 개발	HWP	15	수치 4 · 표 5 · 조건 3 · 비교 1 · 다중 근거 1 · 답 없음 1
10	경상북도 봉화군	봉화군 재난통합관리시스템 고도화 사업(협상)(긴급)	HWP	15	수치 4 · 표 2 · 조건 1 · 비교 2 · 다중 근거 5 · 답 없음 1
11	광주문화재단	2024년 광주문화예술통합플랫폼 시스	HWP	15	수치 2 · 표 3 · 조건 3 · 비교 2 · 다중 근거 4 · 틀린 전제 1
12	조선대학교 SW중심대학사업단	(재공고)2024 조선대학교 SW중심대학 사업관리시스템 (WeHub) 구	HWP	14	수치 4 · 표 4 · 조건 2 · 비교 3 · 다중 근거 1
13	국민연금공단	사업장 사회보험료 지원 고시 개정에 따른 정보시스템 보	HWP	14	수치 2 · 표 5 · 조건 3 · 비교 3 · 다중 근거 1
14	세종테크노파크	세종테크노파크 인사정보 전산시스템 구축 용역 입찰공	HWP	14	수치 3 · 표 3 · 조건 3 · 비교 2 · 다중 근거 3
15	한국원자력연구원	한국원자력연구원 선량평가시스템 고도화	HWP	13	수치 3 · 표 2 · 조건 2 · 비교 3 · 다중 근거 3
16	수산업협동조합중앙회	강릉어선안전조업국 상황관제시스템 구축	HWP	12	수치 4 · 표 2 · 조건 1 · 비교 1 · 다중 근거 3 · 답 없음 1
17	한국건강가정진흥원	2025년 아이돌봄인력 인적성 검사 정보시스템 운영	HWP	12	수치 3 · 표 4 · 조건 3 · 다중 근거 1 · 답 없음 1
18	스포츠윤리센터	스포츠윤리센터 LMS(학습지원시스템) 기능개선	HWP	11	수치 4 · 표 3 · 조건 2 · 다중 근거 2
19	대전대학교	대전대학교 2024학년도 다층적 융합 학습경험 플랫폼 (MILE) 전	HWP	11	수치 3 · 조건 2 · 비교 2 · 다중 근거 4
20	남서울대학교	[혁신-국고] 남서울대학교 스마트 정보시스템 활성화(학사	HWP	11	수치 4 · 조건 3 · 비교 4
21	고려대학교	차세대 포털·학사 정보시스템 구축사업	PDF	11	수치 3 · 조건 2 · 비교 2 · 다중 근거 4
22	한국재정정보원	e나라도움 업무시스템 웹 접근성 컨설팅	HWP	11	수치 4 · 표 1 · 조건 3 · 비교 2 · 다중 근거 1
23	재단법인 예술경영지원센터	통합 정보시스템 구축 사전 컨설팅	HWP	10	수치 3 · 표 2 · 조건 2 · 비교 1 · 다중 근거 1 · 답 없음 1
24	광주과학기술원	실시간통합연구비관리시스템(RCMS) 연계 모듈 변경 사업	HWP	10	수치 3 · 표 4 · 조건 1 · 비교 1 · 다중 근거 1
25	광주과학기술원	학사시스템 기능개선 사업	HWP	10	수치 3 · 표 2 · 조건 2 · 비교 1 · 다중 근거 1 · 답 없음 1
26	인천광역시	인천일자리플랫폼 정보시스템 구축 ISP 수립용역	HWP	9	수치 4 · 표 2 · 조건 2 · 다중 근거 1
27	서영대학교 산학협력단	전문대학 혁신지원사업 서영대학교 차세대 교육	HWP	9	수치 3 · 표 1 · 조건 3 · 비교 1 · 틀린 전제 1
28	경기도 평택시	2024년도 평택시 버스정보시스템(BIS) 구축사업	HWP	9	수치 4 · 조건 2 · 비교 2 · 다중 근거 1
29	케빈랩	평택시 강소형 스마트시티 AI 기반의 영상감시 시스템	HWP	9	수치 3 · 표 4 · 비교 1 · 다중 근거 1
30	부산관광공사	경영정보시스템 기능개선	HWP	8	수치 3 · 표 1 · 조건 2 · 비교 1 · 다중 근거 1

부록 B · test 문서 68개

문항이 많은 순서. dev 30개와 겹치는 문서는 없습니다.

#	발주기관	사업 (파일명 기준, 잘린 이름 포함)	형식	문항	주제별
1	고양도시관리공사	관산근린공원 다목적구장 홈페이지 및 회원 통합운영	HWP	22	수치 5 · 표 9 · 조건 3 · 비교 2 · 다중 근거 3
2	한국철도공사	예약발매시스템 개량 ISMP 용역	HWP	20	수치 4 · 표 4 · 조건 3 · 비교 4 · 다중 근거 4 · 틀린 전제 1
3	한국한의학연구원	통합정보시스템 고도화 용역	HWP	20	수치 4 · 표 7 · 조건 3 · 비교 4 · 다중 근거 1 · 답 없음 1
4	한국지식재산보호원	IP-NAVI 해외지식재산센터 사업관리 시스템 기능개	HWP	19	수치 3 · 표 4 · 조건 2 · 비교 5 · 다중 근거 5
5	경기도사회서비스원	2024년 통합사회정보시스템 운영지원	HWP	19	수치 4 · 표 4 · 조건 2 · 비교 2 · 다중 근거 7
6	인천공항운영서비스	인천공항운영서비스㈜ 차세대 ERP시스템 구축	HWP	19	수치 3 · 표 6 · 조건 3 · 비교 4 · 다중 근거 3
7	한국보건산업진흥원	의료기기산업 종합정보시스템(정보관리기관) 기능개선 사업(2차)	HWP	18	수치 4 · 표 6 · 조건 3 · 비교 2 · 다중 근거 3
8	한국산업단지공단	산단 안전정보시스템 1차 구축 용역	HWP	18	수치 4 · 표 4 · 조건 2 · 비교 2 · 다중 근거 6
9	나노종합기술원	스마트 팹 서비스 활용체계 구축관련 설비온라인 시스	HWP	18	수치 4 · 표 5 · 조건 2 · 비교 2 · 다중 근거 4 · 틀린 전제 1
10	대한상공회의소	기업 재생에너지 지원센터 홈페이지 개편 및 시스템 고	HWP	18	수치 4 · 표 6 · 조건 3 · 비교 2 · 다중 근거 3
11	아시아물위원회 사무국	우즈벡-키르기즈스탄 기후변화대응 스	HWP	17	수치 2 · 조건 4 · 비교 6 · 다중 근거 4 · 틀린 전제 1
12	한국농수산식품유통공사	농산물가격안정기금 정부예산회계연계시스템	HWP	17	수치 4 · 표 6 · 조건 2 · 비교 4 · 다중 근거 1
13	축산물품질평가원	꿀 품질평가 전산시스템 기능개선 사업	HWP	17	수치 3 · 표 5 · 조건 3 · 비교 1 · 다중 근거 5
14	인천광역시 동구	수도국산달동네박물관 전시해설 시스템 구축(협상에	HWP	17	수치 3 · 표 4 · 조건 3 · 비교 3 · 다중 근거 3 · 답 없음 1
15	대한적십자사 의료원	적십자병원 병원정보 재해복구시스템 구축 용역	HWP	16	수치 4 · 표 5 · 조건 3 · 비교 1 · 다중 근거 2 · 틀린 전제 1
16	국방과학연구소	대용량 자료전송시스템 고도화	HWP	16	수치 4 · 표 5 · 조건 3 · 비교 2 · 다중 근거 1 · 답 없음 1
17	한국수자원공사	수도사업장 통합 사고분석솔루션 시범구축 용역	HWP	16	수치 3 · 표 7 · 조건 3 · 비교 1 · 다중 근거 2
18	한국해양조사협회	2024년 항해용 간행물 품질관리 업무보조 시스템 구축	HWP	16	수치 2 · 표 4 · 조건 3 · 비교 2 · 다중 근거 5
19	전라북도 정읍시	정읍체육트레이닝센터 통합운영관리시스템 구	HWP	16	수치 3 · 표 8 · 조건 2 · 비교 1 · 다중 근거 2
20	경기도일자리재단	2025년 통합접수시스템 운영	HWP	16	수치 4 · 표 4 · 조건 3 · 비교 1 · 다중 근거 4
21	한국교육과정평가원	국가교육과정정보센터(NCIC) 시스템 운영 및 개선	HWP	15	수치 4 · 표 4 · 조건 2 · 비교 3 · 다중 근거 2
22	한국산업인력공단	RFID기반 국가자격 시험 결과물 스마트 관리시스템 도	HWP	15	수치 4 · 표 4 · 조건 2 · 비교 1 · 다중 근거 4
23	국가철도공단	철도인프라 디지털트윈 정보화전략계획(ISP) 수립 용역(변	HWP	15	수치 4 · 표 4 · 조건 2 · 비교 1 · 다중 근거 4
24	울산광역시	2024년 버스정보시스템 확대 구축 및 기능개선 용역	HWP	15	수치 4 · 표 4 · 조건 3 · 비교 2 · 다중 근거 2
25	서울시여성가족재단	(재공고, 협상) 서울 디지털성범죄 안심지원센	HWP	15	수치 4 · 표 5 · 조건 3 · 다중 근거 3
26	한국장애인문화예술원	2024년 장애인문화예술정보시스템 이음	HWP	15	수치 4 · 표 6 · 조건 2 · 비교 1 · 다중 근거 2
27	한국수출입은행	(긴급) 모잠비크 마푸토 지능형교통시스템(ITS) 구축사업	HWP	15	수치 4 · 표 2 · 조건 2 · 비교 4 · 다중 근거 2 · 답 없음 1
28	국립중앙의료원	(긴급)「2024년도 차세대 응급의료 상황관리시스템 구축	HWP	15	수치 4 · 표 2 · 조건 3 · 비교 1 · 다중 근거 4 · 틀린 전제 1
29	전북지역혁신플랫폼 대학교육혁신본부	JST 공유대학(원) xAPI기반 LRS시스템 구축	HWP	15	수치 4 · 표 1 · 조건 4 · 비교 1 · 다중 근거 4 · 답 없음 1
30	한국수자원공사	건설통합시스템(CMS) 고도화	HWP	15	수치 3 · 표 7 · 조건 2 · 비교 2 · 다중 근거 1
31	한영대학교	한영대학교 특성화 맞춤형 교육환경 구축 - 트랙운영 학사정보	HWP	14	수치 3 · 조건 1 · 비교 5 · 다중 근거 5
32	한국철도공사	모바일오피스 시스템 고도화 용역(총체 및 1차)	HWP	14	수치 3 · 표 6 · 조건 3 · 다중 근거 2
33	경희대학교 산학협력단	[입찰공고] 산학협력단 정보시스템 운영 용역업체 선정	HWP	14	수치 4 · 표 2 · 조건 3 · 비교 2 · 다중 근거 2 · 답 없음 1
34	한국수자원조사기술원	수문자료정보관리시스템(HDIMS) 재구축 용역(3단계	HWP	14	수치 4 · 표 4 · 조건 3 · 비교 1 · 다중 근거 2
35	한국생산기술연구원	2세대 전자조달시스템 기반구축사업	HWP	14	수치 3 · 표 4 · 조건 3 · 비교 1 · 다중 근거 3
36	인천광역시	도시계획위원회 통합관리시스템 구축용역	HWP	14	수치 4 · 표 4 · 조건 3 · 비교 2 · 다중 근거 1

#	발주기관	사업 (파일명 기준, 잘린 이름 포함)	형식	문항	주제별
37	경기도 안양시	호계체육관 배드민턴장 및 탁구장 예약시스템 구축 용역	HWP	14	수치 3 · 표 4 · 조건 3 · 비교 1 · 다중 근거 2 · 답 없음 1
38	한국대학스포츠협의회	KUSF 체육특기자 경기기록 관리시스템 개발	HWP	14	수치 3 · 표 2 · 조건 3 · 비교 4 · 다중 근거 2
39	한국연구재단	2024년 기초학문자료센터 시스템 운영 및 연구성과물 DB구	HWP	14	수치 3 · 표 4 · 조건 1 · 비교 2 · 다중 근거 4
40	한국사학진흥재단	대학재정정보시스템(기본재산 및 기채 사후관리) 고	HWP	13	수치 4 · 표 2 · 조건 3 · 비교 2 · 다중 근거 2
41	축산물품질평가원	축산물이력관리시스템 개선(정보화 사업)	HWP	13	수치 2 · 표 4 · 조건 3 · 비교 2 · 다중 근거 2
42	국민연금공단	2024년 이러닝시스템 운영 용역	HWP	13	수치 3 · 표 1 · 조건 2 · 비교 2 · 다중 근거 5
43	충북연구원	GIS통계 기반 재난안전데이터 분석 · 관리 시스템 구	HWP	13	수치 3 · 표 1 · 조건 3 · 비교 1 · 다중 근거 5
44	한국사회보장정보원	라오스 보건의료정보화 협력을 위한 사전타당성 조	HWP	13	수치 4 · 표 3 · 조건 2 · 다중 근거 4
45	한국보육진흥원	연차별 자율 품질관리 시스템 기능개선	HWP	13	수치 2 · 표 5 · 조건 3 · 비교 2 · 다중 근거 1
46	한국농어촌공사	네팔 수자원관리 정보화사업-Pilot 시스템 구축용역	HWP	13	수치 4 · 표 1 · 조건 2 · 비교 3 · 다중 근거 3
47	한국전기안전공사	전기안전 관제시스템 보안 모듈 개발 용역	HWP	13	수치 4 · 표 4 · 조건 2 · 비교 1 · 다중 근거 2
48	구미아시아육상경기선수권대회 조직위원회	2025 구미아시아육상경	HWP	12	수치 4 · 표 4 · 조건 2 · 다중 근거 2
49	대한장애인체육회	2025년 전국장애인체육대회 전산 및 시스템, 홈페이지	HWP	12	수치 3 · 표 5 · 조건 1 · 비교 2 · 다중 근거 1
50	보험개발원	실손보험 청구 전산화 시스템 구축 사업	HWP	12	수치 4 · 표 4 · 조건 2 · 다중 근거 2
51	수산업협동조합중앙회	수협중앙회 수산물사이버직매장 시스템 재구축 ISMP 수립 입	HWP	12	수치 3 · 표 5 · 조건 2 · 비교 1 · 다중 근거 1
52	중앙선거관리위원회	2025년도 행정정보시스템 위탁운영사업	HWP	12	수치 4 · 표 1 · 조건 3 · 비교 3 · 다중 근거 1
53	국방과학연구소	기록관리시스템 통합 활용 및 보안 환경 구축	HWP	12	수치 3 · 표 1 · 조건 2 · 비교 3 · 다중 근거 3
54	한국가스공사	[재공고]차세대 통합정보시스템(ERP) 구축	HWP	10	수치 3 · 표 1 · 조건 2 · 비교 3 · 다중 근거 1
55	그랜드코리아레저	2024년도 GKL 그룹웨어 시스템 구축 용역	HWP	10	수치 3 · 표 2 · 조건 2 · 비교 1 · 다중 근거 2
56	국립민속박물관	2024년 국립민속박물관 민속아카이브 자	HWP	10	수치 1 · 표 3 · 조건 3 · 비교 1 · 다중 근거 2
57	국립인천해양박물관	국립인천해양박물관 해양자료관리시스템 구축 용	HWP	10	수치 4 · 표 2 · 조건 2 · 비교 1 · 다중 근거 1
58	파주도시관광공사	종량제봉투 판매관리 전산시스템 개선사업	HWP	10	수치 4 · 조건 1 · 비교 2 · 다중 근거 3
59	부산국제영화제	2024년 BIFF & ACFM 온라인서비스 재개발 및 행사지원시	HWP	10	수치 2 · 조건 3 · 비교 3 · 다중 근거 2
60	벤처기업확인기관	2024년 벤처확인종합관리시스템 기능 고도화 용역사업	HWP	9	수치 4 · 표 1 · 조건 2 · 비교 1 · 다중 근거 1
61	한국국제협력단	[긴급] [지문] [국제] 우즈베키스탄 열린 의정활동 상하원	HWP	9	수치 4 · 표 2 · 조건 2 · 다중 근거 1
62	기초과학연구원 중이온가속기연구소	2025년도 중이온가속기용 극저온시스템 운전 용역	PDF	9	수치 3 · 조건 2 · 비교 2 · 다중 근거 2
63	한국발명진흥회	2024년 건설기술에 관한 특허·실용신안 활용실	HWP	9	수치 3 · 표 1 · 조건 1 · 비교 1 · 다중 근거 2 · 답 없음 1
64	대검찰청	아태 사이버범죄 역량강화 허브(APC-HUB) 홈페이지 및 온라인 교	HWP	9	수치 3 · 조건 2 · 비교 2 · 다중 근거 2
65	서울시립대학교	[사전공개] 학업성취도 다차원 종단분석 통합시스템 1차	PDF	8	수치 3 · 조건 2 · 비교 2 · 다중 근거 1
66	광주연구원	광주정책연구아카이브(GPA) 시스템 개발	HWP	8	수치 3 · 조건 3 · 비교 1 · 다중 근거 1
67	서울특별시	2024년 지도정보 플랫폼 및 전문활용 연계 시스템 고도화 용	PDF	8	수치 3 · 조건 3 · 비교 1 · 다중 근거 1
68	한국수자원공사	용인 첨단 시스템반도체 국가산단 용수공급사업 타당성	HWP	7	수치 4 · 조건 2 · 다중 근거 1

부록 C · 출처

이 보고서의 수치를 옮겨 온 곳입니다. 발표 자료에 숫자를 인용할 때 이 파일을 함께 표기하세요.

절	파일	내용
① 만들기	`golden_pipeline/README.md` , `golden_pipeline/outputs/` 실행 매니페스트	생성 · 검증 · 출시 단계, 후보 · 출시 수, 비용
	`golden_pipeline/experiment_abc7.md`	A · B · C 비교
	`golden_pipeline/prompts/A/*.txt` · `B.txt` , `configs/topics/*.json` , `generation.py` , git 이력, dev.jsonl의 `prompt_version`	주제별 규칙 인용, 판별 dev 문항 수
② ③ 분포	`eval/golden/manifest.json` · `dev.jsonl` · `test.jsonl` (final6)	이 보고서를 위해 파일에서 직접 집계
④ 분할	`golden_pipeline/split.py` , `golden_pipeline/plan.py` , `golden_pipeline/adoption.py`	분할 규칙 · 시드 · 답 없음 처리
⑤ 눈금	`README.md` 골든 라벨 연결 절, `docs/benchmarks/seven_model/full_dev/report.md`	라벨 연결률, 청크 제외율 51.5%
⑥ 쓰는 법	`README.md` 최종 test 평가 절, `docs/eval_ir_sample.md` , `최종평가_결과/지표/`	dev 표본 비용, test 절차, 최종 평가 문항 수 · 라벨 연결률

원시 질문 · 정답 · 근거는 git에서 제외된 로컬 `artifacts/` 에 있어 팀원 PC에서는 복원 명령(`python -m rag.validation.local_inputs`) 이 필요합니다.