공공기관 RFP 질의응답 시스템 평가 보고서

청킹 방식과 메타데이터 필터 비교, 최종 성능 · 응답 시간 · 비용

작성일	2026-10-21
대상 문서	공공기관 RFP 98건
평가 질문	dev 384문항(설정 비교), test 880문항(최종 확인)

1 · 요약

구조 기반 청킹에 기관 필터를 켜면, 처음 보는 질문도 대부분 맞힌다

83.7%
test 정답률(답할 수 있는 질문 기준)

0.915
Evidence Coverage (test)

5.0초 · 6.9초
질문 하나의 전체 응답 시간 p50 · p90(test)

약 0.72달러
질문 1,000건에 드는 언어 모델 이용료

- 구조 기반 청킹과 길이 기반 청킹의 검색 지표는 비슷하다. Chunk MRR@10은 구조 기반이, Doc MRR@10은 길이 기반이 조금 높다.
- 구조 기반은 기관 필터가 있어야 제대로 동작한다. 필터를 끄면 비슷한 RFP끼리 섞인다.
- 틀린 답은 여러 근거를 모아야 하는 질문에 몰려 있다.
- 응답 시간은 대부분 언어 모델을 두 번 부르는 데 쓰인다. 문서를 찾는 데는 거의 시간이 들지 않는다.

2 · 평가 방법

질문은 세 단계를 거쳐 답이 되고, 네 가지 평가로 나누어 채점했다

① 질문 다듬기

앞선 대화를 반영해 질문을 검색하기 좋게 고쳐 쓴다

② 문서 찾기

RFP 98건에서 질문과 관련된 청크를 찾아 답변 모델에 넘긴다

③ 답변 작성

넘겨받은 청크만 보고 답을 쓴다

평가	지표	보는 것
Retrieval	Doc Recall@k	상위 k개 청크(5 · 10 · 20)에 든 정답 문서의 비율
	Chunk Recall@k	상위 k개 청크에 든 정답 근거 청크의 비율
	Doc · Chunk MRR@10	상위 10개 청크 중 첫 정답 순위의 역수 (없으면 0)
	Evidence Coverage Full Evidence Coverage	정답 근거 청크 가운데 답변 모델에 넘어간 몫 / 전부 넘어갔는지
	Key Fact Match (context)	넘긴 글에 정답 핵심 문구가 든 몫
Generation	Key Fact Match (answer)	답변에 정답 핵심 문구가 든 몫
Grounding	Faithfulness	답변 가운데 넘긴 글로 뒷받침되는 몫
End-to-End	Factual Correctness (F1)	답변과 정답의 내용이 겹치는 정도
	정답률	Factual Correctness ≥ 0.5 또는 Key Fact Match (answer) = 1인 질문의 비율
	응답 시간 p50 · p90	질문 절반(p50), 열에 아홉(p90)이 끝난 시간

순위는 청크 단위로 세고, 같은 문서의 청크도 각각 센다. 응답 시간을 뺀 지표는 질문마다 낸 0~1 점수의 평균이다. 정답률은 답할 수 있는 질문 가운데 비율(%)이고, 응답 시간은 초 단위다. Key Fact Match는 띄어쓰기와 숫자 표기를 맞춘 뒤 비교한다. Faithfulness와 Factual Correctness는 RAGAS로 재고, 채점 모델은 gpt-5-mini다.

3 · 청킹 방식

길이 기반은 글자 수로 자르고, 구조 기반은 문서의 짜임새대로 자른다

	길이 기반 700자	구조 기반
자르는 기준	700자를 넘지 않게 자른다. 문단, 줄, 문장이 끝나는 곳을 먼저 찾아 자르고, 앞 청크와 최대 140자까지 겹치게 했다.	같은 제목 아래 본문을 한 덩어리로, 요구사항은 번호 하나(예: PER-001)를 한 덩어리로 묶는다. 너무 길면 나눈다. 목차 쪽은 뺀다.
표	다른 글처럼 길이로 자른다. 행 중간에서 잘릴 수 있다.	행 단위로 나누고, 나눈 조각마다 표의 머리글 행을 다시 붙인다. 합쳐진 칸은 풀어서 적는다.
청크 앞에 붙는 글	문서 이름과 제목	제목. 요구사항 청크에는 검색할 때 요구사항 번호와 이름도 붙인다. 문서 이름은 없다.
검색할 때	찾은 청크만 넘긴다.	같은 요구사항이나 같은 표에서 나온 청크를 함께 넘긴다.

길이 기반은 구조 기반 청크를 만든 원래 글을 다시 모아 잘랐다. 그림에서 읽어 낸 글 일부는 길이 기반에 없다. 검색 색인은 청킹마다 새로 만들었다.

4 · 청크 길이

구조 기반은 짧은 청크가 많고, 길이가 크게 들쭉날쭉하다

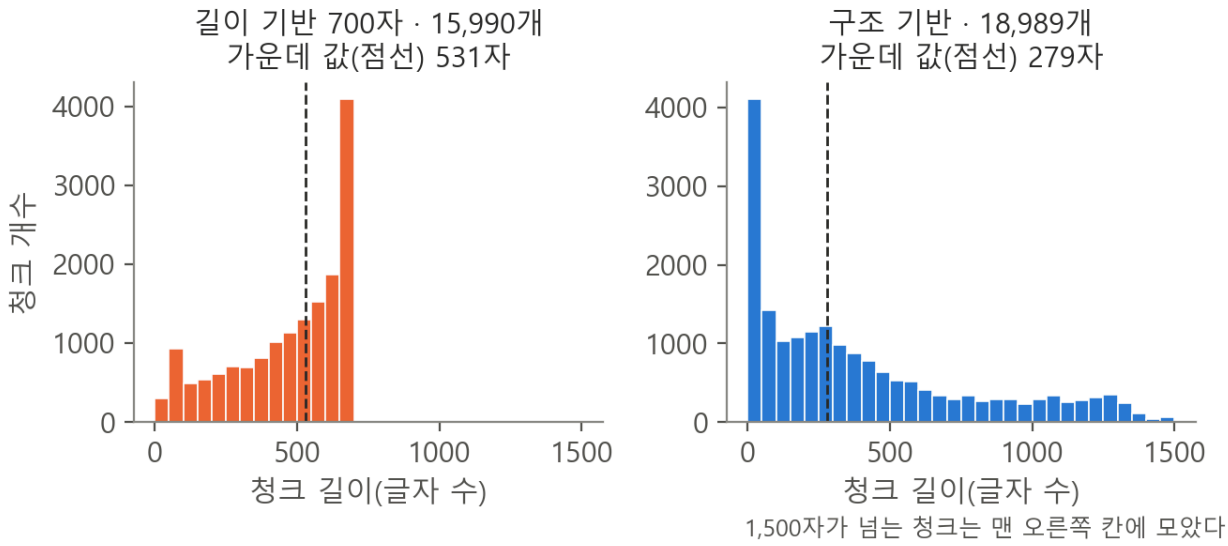


표 한 행이나 제목 한 줄이 그대로 청크 하나가 되기 때문이다. 반대로 긴 요구사항이나 표는 한 청크에 길게 담긴다.

5 · 청킹 비교

두 방식의 검색 지표는 비슷하다. 구조 기반은 정답 청크를, 길이 기반은 정답 문서를 조금 더 위에 올린다

지표 (dev, 기관 필터 켬)	구조 기반	길이 기반 700자
Doc Recall@5	0.985	0.996
Doc Recall@10	0.989	0.996
Doc Recall@20	0.993	1.000
Doc MRR@10	0.985	0.996
Chunk Recall@5	0.914	0.903
Chunk Recall@10	0.955	0.946
Chunk Recall@20	0.964	0.970
Chunk MRR@10	0.785	0.768
Evidence Coverage	0.944	0.946
Full Evidence Coverage	0.936	0.940

두 방식 모두에서 정답 근거의 위치를 확인할 수 있는 dev 267문항 기준이다.

두 방식은 자르는 법 말고도 다른 점이 있다. 길이 기반 청크에는 문서 이름이 붙는다. 구조 기반은 요구사항 번호와 이름을 붙여 검색하고, 같은 요구사항이나 같은 표의 청크를 함께 넘긴다. 입력 글도 조금 다르다. 그래서 이 차이를 자르는 법만의 효과로 볼 수는 없다.

6 · 메타데이터 필터

구조 기반은 기관 필터 없이는 비슷한 RFP끼리 섞인다

청킹	기관 필터	Doc Recall@10	Chunk Recall@10	Chunk MRR@10	Evidence Coverage
구조 기반	켬	0.989	0.955	0.785	0.944
구조 기반	끔	0.921	0.502	0.245	0.524
길이 기반 700자	켬	0.996	0.946	0.768	0.946
길이 기반 700자	끔	0.996	0.867	0.660	0.906

기관 필터는 질문에 발주 기관 이름이 나오면 그 기관의 문서 안에서만 찾는다. 구조 기반 청크에는 문서 이름이 없고, 표 머리글이나 서식처럼 여러 문서에 똑같이 나오는 짧은 청크가 많다. 범위를 좁혀 주지 않으면 다른 기관의 비슷한 청크가 먼저 걸린다.

앞 쪽과 같은 dev 267문항 기준이다. 기관 필터를 끈 쪽도 수량 조건 필터는 켰다.

예산이나 기간 같은 조건으로 사업을 거르는 수량 조건 필터는 켜도 꺼도 결과가 같았다. 실제 검색에 쓴 다듬은 질문 가운데 이 필터가 쓰일 질문이 dev와 test 모두 없었다. 이번 평가로는 이 필터의 효과를 알 수 없다.

7 · 최종 결과

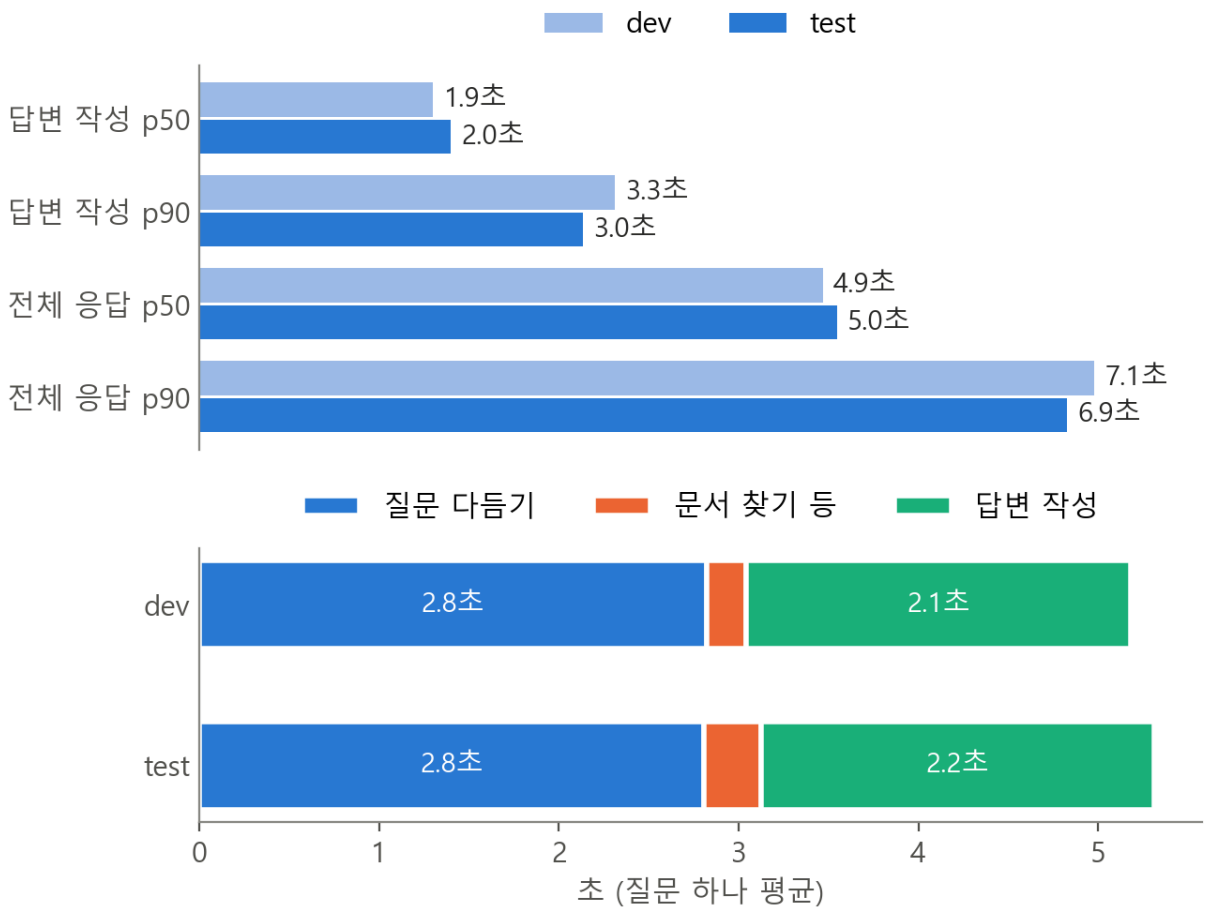
test에서도 dev와 비슷한 수준으로 맞혔다

평가	지표	dev	test	문항 (dev / test)
Retrieval	Doc Recall@5	0.987	0.994	376 / 872
	Doc Recall@10	0.992	0.994	376 / 872
	Doc Recall@20	0.995	0.997	376 / 872
	Doc MRR@10	0.987	0.993	376 / 872
	Chunk Recall@5	0.913	0.891	316 / 718
	Chunk Recall@10	0.957	0.937	316 / 718
	Chunk Recall@20	0.968	0.970	316 / 718
	Chunk MRR@10	0.774	0.749	316 / 718
	Evidence Coverage	0.948	0.915	316 / 718
	Full Evidence Coverage	0.940	0.909	316 / 718
	Key Fact Match (context)	0.960	0.926	376 / 872
Generation	Key Fact Match (answer)	0.674	0.621	384 / 880
Grounding	Faithfulness	0.800	0.769	384 / 880
End-to-End	Factual Correctness (F1)	0.397	0.403	384 / 880
	정답률	85.4%	83.7%	376 / 872

평가 문항은 골든 dev 408 · test 943문항 가운데 핵심 사실을 뽑을 수 있는 문항이다. 핵심 사실이 없는 다중 근거 문항(dev 24 · test 63)은 뺐다.

Key Fact Match는 넘긴 글(context)보다 답변(answer)에서 크게 낮다. 근거를 받고도 답에 옮기지 못했거나, 같은 내용을 다른 말로 쓴 경우가 섞여 있다. Factual Correctness가 낮은 까닭은 10장에 있다.

응답 시간은 대부분 언어 모델을 두 번 부르는 데 쓴다

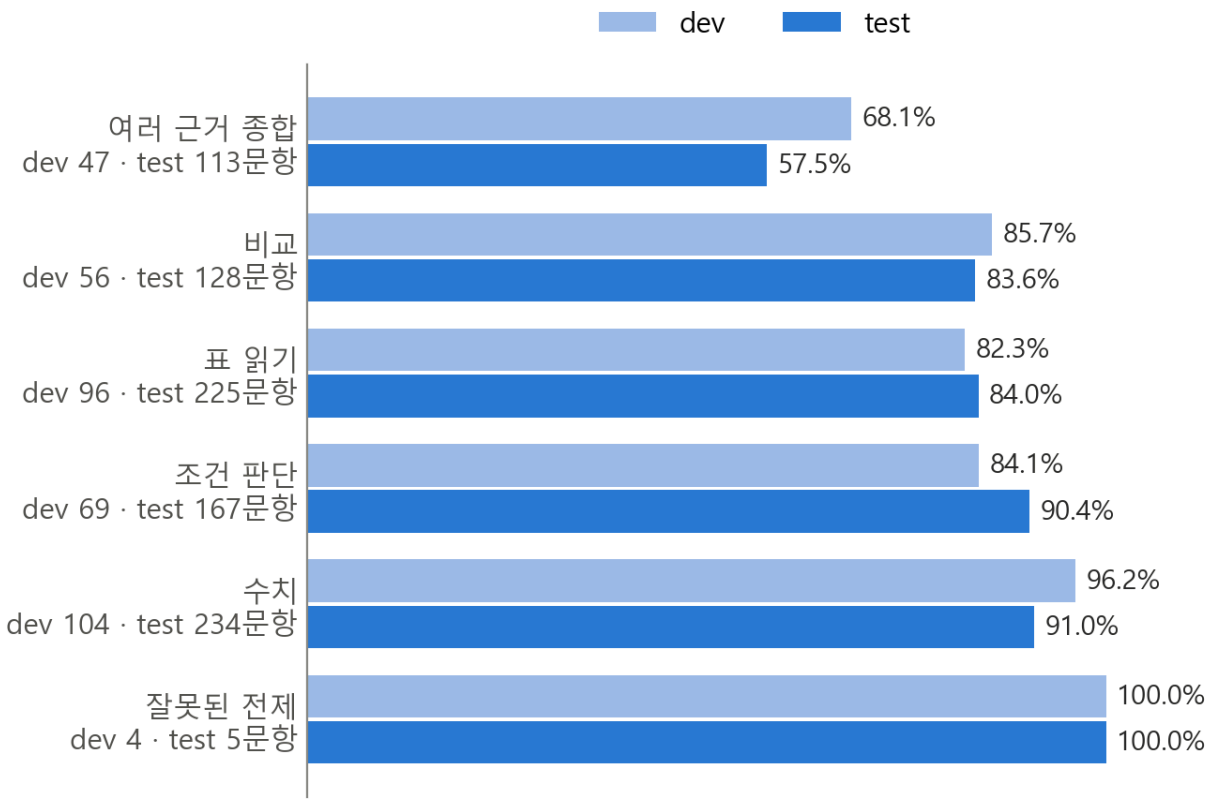


문서 찾기 등은 전체 시간에서 질문 다듬기와 답변 작성 시간을 뺀 나머지다.

질문 다듬기와 답변 작성은 외부 언어 모델 서비스의 응답을 기다리는 시간이라, 이용 상황에 따라 달라질 수 있다. 응답을 더 빠르게 하려면 질문 다듬기를 줄이는 쪽이 효과가 크다. 앞선 대화가 없는 첫 질문은 다듬기를 건너뛰는 방법이 있다.

9 · 질문 종류별 결과

여러 근거를 모아야 하는 질문의 정답률이 가장 낮다

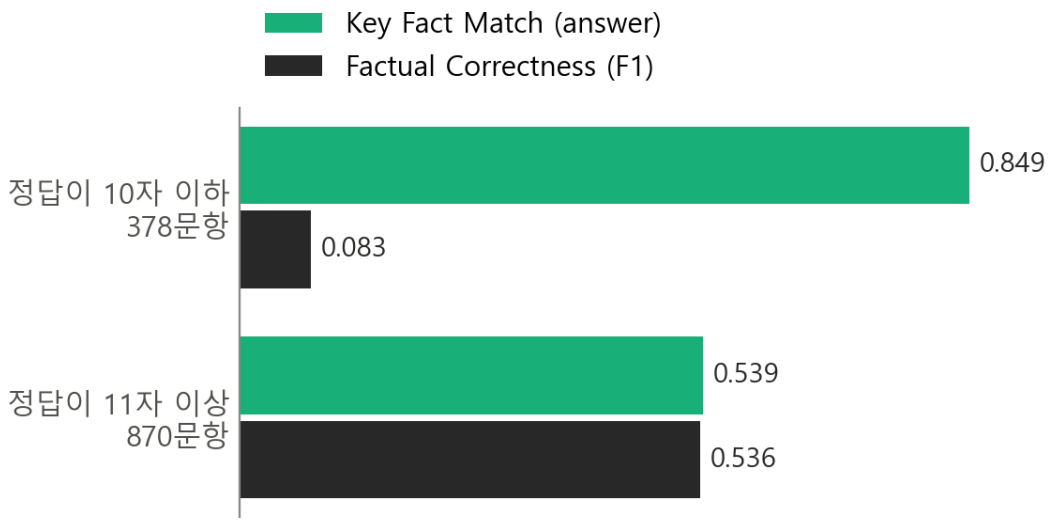


다중 근거는 핵심 사실을 뽑을 수 있는 dev 47 · test 113문항만 채점했다.

이런 질문은 근거가 문서 여러 곳에 흩어져 있어, 그중 하나만 놓쳐도 답이 불완전해진다.

10 · 채점 모델의 한계

채점 모델은 정답이 짧으면 맞는 답에도 낮은 점수를 준다



dev와 test를 합쳐, 답할 수 있는 질문만 셌다.

질문 한국철도공사의「운행정보기록 자동분석시스」사업에서 착수일로부터 사업기간은 얼마인가?

정답 180일

답변 한국철도공사의「운행정보기록 자동분석시스템 개량」사업기간은 착수일로부터 180일입니다. [3]

점수 Factual Correctness 0.000 · Key Fact Match (answer) 1.000

그래서 정답률은 Factual Correctness만 보지 않고, Key Fact Match (answer)가 1이면 맞힌 것으로 셌다.

11 · 틀린 답 분석

틀린 답에는 필요한 근거가 빠진 경우와 근거를 받고도 못 쓴 경우가 비슷하게 섞여 있다



막대 길이는 비율, 안쪽 숫자는 문항 수다. 답할 수 있는 질문(dev 376 · test 872)만 셌다.

필요한 근거가 빠진 예: 같은 모양의 요구사항 표가 여러 개라, 질문과 다른 표를 가져왔다

질문 을지대학교의「을지대학교 비교과시스템 개발」사업에서 세부 내용 행의 기능요구사항은 무엇인가?

정답 1 체크리스트 생성 및 관리, 2 서류 현황 확인, 3 최종 신청 완료 프로세스(각 세부 항목은 생략)

답변 기능요구사항의 세부 내용은 운영부서 대시보드 구성으로, 공지사항 · 프로그램 목록 · 달력과 부서별 프로그램 운영 현황 및 성과지표 등을 제시하는 내용입니다. [4]

근거를 받고도 못 쓴 예: 근거에 "20억원 미만"이 있었는데, 실제 사업 예산을 답했다

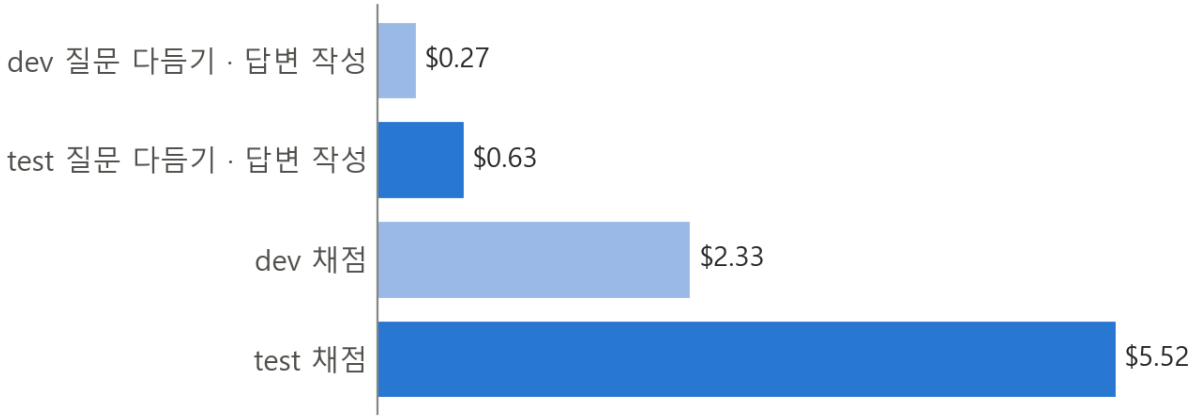
질문 경기도 평택시의「2024년도 평택시 버스정보시스템(BIS) 구축사업」사업에서 사업금액의 기준 금액은 얼마인가?

정답 20억원 미만

답변 사업금액의 기준 금액은 ₩999,494,600원(부가세 포함)입니다. [1]

12 · 비용

평가 비용은 대부분 채점에 들었고, 시스템을 돌리는 이용료는 아주 적다



이번 평가에 든 언어 모델 이용료는 모두 8.76달러다. 채점은 평가할 때만 들고, 실제 서비스에서 질문을 처리할 때는 질문 다듬기와 답변 작성 이용료가 든다. 검색은 이 PC에서 돌아 이용료가 없고, 서버 운영비는 넣지 않았다.

13 · 남은 과제

아직 확인하지 못한 것과 다음에 할 일

아직 확인하지 못한 것

- 청킹 비교 결과에는 자르는 법 말고도 문서 이름과 요구사항 번호를 붙였는지, 같은 요구사항의 청크를 함께 넘겼는지, 입력 글의 작은 차이가 섞여 있다.
- 여러 사업을 예산이나 기간 조건으로 골라내는 질문이 없어, 수량 조건 필터의 효과를 재지 못했다.
- dev와 test는 질문을 만든 문서가 겹치지 않는다(30건 · 68건). 다만 기관 목록과 단어 사전은 98건 전체로 만들어, 목록에 없는 새 기관의 RFP에서의 성능은 모른다.

다음에 할 일

- 구조 기반 청크 앞에도 문서 이름을 붙여 색인을 다시 만들고, 기관 필터 없이도 정답 근거를 찾는지 확인한다. 색인을 다시 만드는 데는 언어 모델 이용료가 들지 않는다.
- 답변 지시문을 고쳐 표의 행과 열을 짚어 읽고, 질문이 묻는 항목의 값을 골라 답하게 한다.
- 짧은 정답은 문자를 직접 비교해 채점하고, 채점 모델은 서술형 정답에만 쓴다.
- 사업을 예산이나 기간 조건으로 골라내는 질문을 따로 만들어 수량 조건 필터를 평가한다.

부록

결과를 다시 만드는 방법

순서	명령	하는 일
1	s01_build_chunkings.py	두 방식으로 청크를 만들고 색인을 새로 만든다
2	s02_label_sets.py	청킹마다 질문의 정답 근거 청크를 표시한다
3	s03_generate.py dev v12 both_on	dev 질문에 답한다(유료)
4	s04_retrieval_grid.py (3번의 dev answers.jsonl 경로)	청킹 2가지 × 필터 4가지 검색 비교 (무료)
5	s03_generate.py test v12 both_on	test 질문에 답한다(유료)
6	s05_evaluate.py dev v12 both_on	dev 답변을 채점한다(유료)
7	s05_evaluate.py test v12 both_on	test 답변을 채점한다(유료)
8	s06_aggregate.py v12 both_on	표와 그림을 만든다

모든 명령은 재현/scripts 폴더에서 python으로 하나씩 차례로 실행한다. 폴더: 지표(숫자 표, 본문 표 1~3 포함), 그래프(그림 1~6), 문항별(질문마다 점수와 답변), 재현(실행 파일, 설정, 비용 기록).
문항별 결과에는 실제 RFP 질문과 답변이 들어 있어 Git에 올리지 않는다.