골든 데이터셋을 만드는 세 방식, 일곱 주제에서 견줘 보니

같은 근거 묶음 42개를 세 방식에 똑같이 주고, 같은 독립 검증기로 걸렀습니다. 견준 것은 **평가 데이터셋을 만드는 방식**이고, RAG 답변 시스템은 견주지 않았습니다.

실험 2026-10-18 · 작성 2026-10-19 · 실험 id `abc7` · 실험 고정 커밋 `622a9d1` · 결과 기록 커밋 `9a4ccfe` · 생성·검증 모델 gpt-5-mini

A · 주제 전용

주제마다 전용 프롬프트를 씁니다. 실패 기록을 참고해 처음 시도를 포함해 최대 세 차례 만듭니다.

50% 21 / 42 묶음

B · 고정 프롬프트

일곱 주제가 프롬프트 하나를 함께 씁니다. 한 번만 만듭니다.

33% 14 / 42 묶음

C · 웹 Pro 채팅

사람이 웹 채팅(`gpt 6 pro` 표시)에 붙여 넣고 첫 응답을 그대로 가져옵니다.

48% 20 / 42 묶음

숫자는 **첫 시도 커버리지**입니다. 검증을 통과한 질문이 하나라도 나온 근거 묶음의 비율이고, A는 1차 시도(A1)만 셉니다.

먼저 알아야 할 네 가지

1 주제 전용 프롬프트(A1)가 고정 프롬프트(B)보다 나은 쪽으로 보입니다

첫 시도 커버리지 21/42 대 14/42. 에이전트가 판정한 품질도 같은 쪽(8/14 대 5/14)입니다. 다만 주제마다 순서가 바뀝니다.

2 A의 자가개선 루프는 효과가 없습니다

별도 실험(`a30v12` , 다단계·표는 검사를 고친 뒤 `a30v12f`)에서 validation을 주제당 30묶음으로 늘려 다시 쟀습니다. 시험한 예방 규칙 9개 중 다단계의 1개만 채택됐고, 그 규칙도 held-out 30묶음에서는 같은 기준을 넘지 못했습니다. v12에서 새로 고른 train 42묶음의 커버리지는 24/42에서 31/42로 늘었는데, 거절된 묶음에 그 묶음의 실패 기록을 붙여 다시 만든 결과입니다. 위 A1의 21/42와는 다른 묶음입니다.

3 C는 A1과 비슷하지만, 방식의 차이만 비교한 결과가 아닙니다

모델과 인터페이스가 다릅니다. 생성 비용은 관측하지 못했고, 측정한 것은 검증 비용 0.23 USD와 사람 처리 시간 약 21분입니다.

4 답 없음(unanswerable) 주제는 세 방식 모두 0/6입니다

거절 이유는 대부분 '대상 문서에 있음'입니다. 문서에 없다고 만든 질문의 답이 실제로는 그 문서에 있었습니다.

2쪽 ① 무엇을 견줬나 — 세 방식이 같은 것과 다른 것, 비교 기준

3쪽 ② 주제와 지표 — 일곱 주제의 통과 조건, 지표 다섯 개

4–8쪽 ③ 결과 — 커버리지 · 거절 이유 · A 반복 · 비용 · 검토

9쪽 ④ 해석과 한계 — 말할 수 있는 것과 없는 것

10–11쪽 부록 — 근거 고정 · 장부 · 검증 순서

① 무엇을 어떻게 견줬나

근거 묶음, 검증 기준, 실험 상태는 세 방식이 같게 맞췄습니다. A·B는 같은 모델에서 프롬프트만 달리했고, C는 모델과 입력 방식도 달라 방식만의 효과를 따로 떼어 볼 수 없습니다.



세 방식에서 같은 것과 다른 것

항목	A	B	C
근거 묶음	같음 주제마다 고정한 train 6묶음, 같은 컨텍스트(묶음당 4,000자 이하)		
검증	같음 같은 검증기·판정기 프롬프트, 같은 규칙과 주제 명세. 실험 중에 바꾸지 않음		
실험 상태	같음 지난 실패 기록·통과 항목·묶음 소유를 읽지 않음. 어느 방식도 과거 결과의 도움을 받거나 방해받지 않음		
프롬프트	주제마다 하나씩, 7개	고정 글 하나	B처럼 고정 글에 주제 명세만 넣음
생성 모델	gpt-5-mini, 추론 low	gpt-5-mini, 추론 low	다름 웹 화면 표시 `gpt 6 pro`
부르는 단위	묶음마다 한 번	묶음마다 한 번	다름 주제마다 6묶음을 한 메시지로
다시 시도	처음 시도를 포함해 최대 3차. 2차부터 이 실험 1차 시도의 실패만 읽음	없음	없음. 첫 응답 그대로

비교 기준은 '첫 시도끼리'입니다

A의 1차 시도(A1)만 B·C와 맞대고, 2·3차 반복은 6쪽에서 따로 봅니다. 반복의 효과는 validation을 30묶음으로 늘린 별도 실험(`a30v12` , 다단계·표는 `a30v12f`)으로 다시 쟀습니다. 재시도는 같은 근거 묶음으로 질문을 다시 만드는 일이라, 전체 결과를 첫 시도와 견주면 시도 횟수의 차이가 결과에 섞입니다.

② 일곱 주제와 지표 다섯 개

결과를 읽기 전에 필요한 정의입니다. 주제마다 '통과'의 조건이 다르고, 지표는 모두 분자와 분모를 함께 남깁니다.

주제마다 통과하려면

주제	후보가 되려면 (주제 명세)
수치 `numeric`	답의 값·단위 쌍이 인용한 근거에 통째로 있어야 합니다. `30,000,000원` 과 `130,000,000원`, `12개` 와 `12개월` 은 서로 다른 값으로 봅니다.
표 `table`	인용한 표의 행 이름과 열 이름이 만나는 칸의 값이 답에 있어야 합니다.
조건 `condition`	근거에 있는 조건·예외 문구가 답에 함께 있어야 합니다.
비교 `comparison`	서로 다른 대상 2개 이상과 각 대상의 값이 근거에 있고, 그중 하나를 골라야 합니다. 고르지 않고 값만 나란히 묻는 질문은 거절합니다.
다단계 `multi_hop`	근거 단위 2개 이상이 필요하고, 근거를 하나씩만 주면 답할 수 없어야 합니다.
답 없음 `unanswerable`	다른 문서에 있는 속성을 이 문서에 묻습니다. 답은 정확히 '제공된 문서에서 확인할 수 없습니다.'이고, 이 문서 전체를 읽은 검증기도 답하지 못해야 합니다.
틀린 전제 `false_premise`	질문이 사실처럼 깔고 있는 잘못된 값(`stated`)이 문서 어디에도 없어야 합니다. 답은 근거에 있는 실제 값(`actual`)으로 전제를 바로잡고, 두 값은 단위가 같고 수만 달라야 합니다.

'통과'는 이렇게 정해집니다

1 · 무료 검사
구조·규칙·중복
주제 구조, 평가에 쓸 수 없는 꼴, 이미 통과한 질문과의 중복. 돈이 들지 않는 검사를 먼저 합니다.

→

2 · 검증기
근거만으로 따로 답하기
질문과 근거만 받아 답을 냅니다. 근거끼리 충돌하는지, 근거로 답할 수 있는지도 봅니다.

→

3 · 판정
두 답이 같은가
정규화해서 비교하고, 그래도 정하지 못하면 판정기에 맡깁니다. 끝까지 통과하면 `auto_validated`.

처음 걸린 검사에서 멈추고, 그 검사의 이름이 거절 이유가 됩니다. 전체 순서는 부록 B에 있습니다.

지표 다섯 개

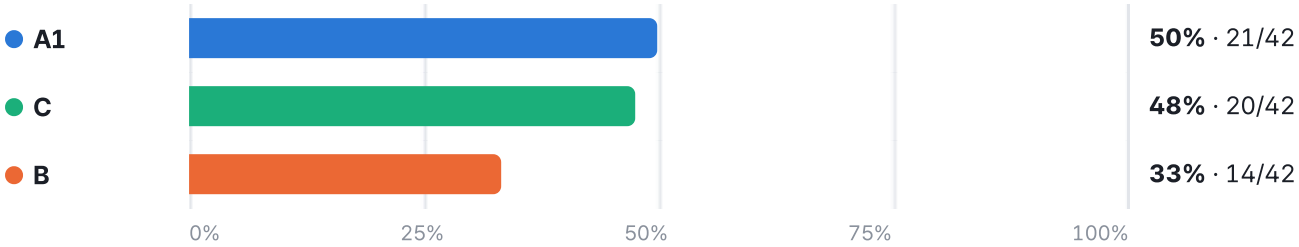
지표	분자	분모
쓸 수 있는 묶음 커버리지	통과한 질문이 하나라도 있는 묶음	배정한 비교 묶음 (주제마다 6)
출력 수용률	통과한 질문	돌아온 모든 출력 (JSON이 아니거나 필드가 틀린 것도 포함)
전달 완결성	출력이 하나라도 돌아온 묶음	배정한 묶음
유효 질문당 API 비용	그 방식의 모든 호출 비용 (생성·검증·판정·다시 보낸 호출)	공백·쉼표만 다른 것을 하나로 센 통과 질문. 0개면 `값 없음`
검토한 품질	네 검사를 모두 통과한 표본 출력	검토한 출력 (방식·주제·층별). 정의는 8쪽

읽을 때 주제마다 묶음이 6개라 묶음 하나가 **17%p**입니다. 주제별 차이는 방향만 보여 줍니다. 첫 시도(A1·B·C)는 묶음마다 출력이 하나씩이라 커버리지와 출력 수용률이 같습니다.

③ 결과 1 · 첫 시도 커버리지

전체로는 A1과 C가 비슷하고 B가 뒤처집니다. 하지만 주제마다 앞서는 방식이 바뀝니다.

전체 (42묶음)



전달 완결성 42/42 세 방식 모두 모든 묶음에서 출력이 돌아왔습니다 **pending 0** 판정이 남은 후보가 없습니다

주제별 (각 6묶음)

	A1	B	C
수치	6/6	3/6	5/6
표	3/6	2/6	4/6
조건	3/6	1/6	3/6
비교	2/6	3/6	6/6
다단계	3/6	2/6	2/6
답 없음	0/6	0/6	0/6
틀린 전제	4/6	3/6	0/6

0 6묶음

무엇이 보이나

- **C가 앞선 곳:** 비교 6/6, 표 4/6
- **A1이 앞선 곳:** 수치 6/6, 틀린 전제 4/6
- **B**가 단독으로 앞선 주제는 없고, 비교(3/6)에서만 A1보다 앞섭니다
- **답 없음**은 세 방식 모두 0/6입니다
- **C의 틀린 전제 0/6**은 유형 불일치 3, 독립 답과 다름 2, 전제가 문서에 있음 1입니다

한 칸 차이는 17%p

주제마다 6묶음이라 칸마다 차이가 크게 보입니다. 예를 들어 비교 주제의 C 6/6 대 A1 2/6은 묶음 4개 차이입니다. 순위로 읽지 말고 방향으로 읽어야 합니다.

③ 결과 2 · 왜 거절됐나

첫 시도에서 통과하지 못한 출력이 처음 걸린 검사입니다. 셋 다 많이 걸린 것은 '대상 문서에 있음'과 '조건·예외 누락'이고, B는 '유형 불일치'가 특히 많습니다.

거절 이유	걸리는 경우	A1	B	C
유형 불일치 `type_mismatch`	주제가 요구하는 구조를 못 맞춤	5	9	3
대상 문서에 있음 `present_in_target`	'답 없음' 질문의 답이 문서에 있음	5	5	6
조건·예외 누락 `missing_condition`	답을 제한하는 조건이 답에 없음	3	3	4
근거가 한 청크 `single_chunk`	다단계인데 근거가 모두 한 청크	1	3	2
독립 답과 다름 `answer_mismatch`	검증기의 답과 후보 답이 다름	0	1	3
표 관계 `table_relation`	행·열이 만나는 칸 값이 답에 없음	1	2	1
multi_hop 아님 `not_multi_hop`	근거 하나만으로도 답이 나옴	2	0	0
전제가 문서에 있음 `premise_in_document`	'틀린' 전제가 실제로 문서에 있음	0	2	1
그 밖	형식 오류·끊긴 질문·답 덧붙임·근거 지칭·검증기 출력 오류 등, 각 1건	4	3	2
거절 합계	통과 + 거절 = 42	**21**	**28**	**22**

막대는 한 칸에 나온 가장 큰 값(B의 유형 불일치 9건)에 맞춘 길이입니다. '그 밖'에는 A1 형식 오류·끊긴 질문·답 덧붙임·근거 지칭, B 형식 오류·끊긴 질문·근거로 답할 수 없음, C 형식 오류·검증기 출력 오류가 들어 있습니다.

눈에 띄는 것

- B의 거절 28건 중 9건이 **유형 불일치**입니다. 주제 구조를 맞추지 못한 경우가 셋 중 가장 많습니다.
- **대상 문서에 있음**은 A1·B·C에서 5·5·6건으로 셋 다 많습니다. 주제 설계, 묶음 고르기, 생성 방식 중 무엇 때문인지는 이번 결과로 알 수 없습니다.

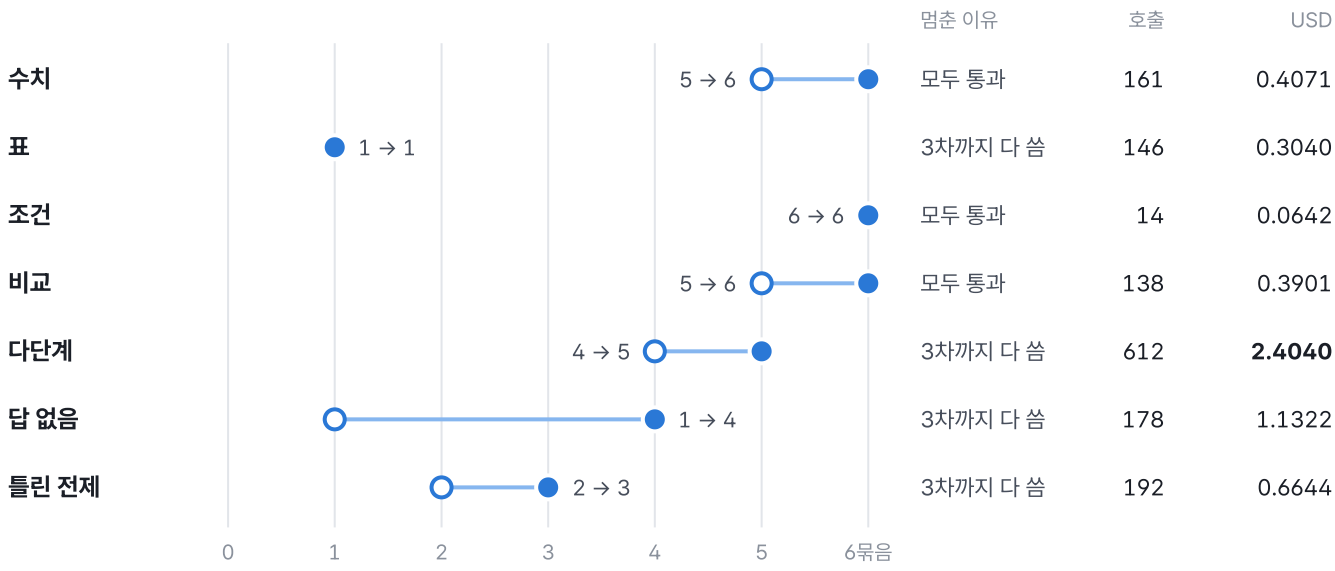
C에서만 두드러진 것

- **독립 답과 다름** 3건. 다른 모델이 만든 답을 gpt-5-mini 검증기가 다르게 읽은 경우가 섞였을 수 있습니다.
- 형식 오류는 세 방식 모두 1건입니다. C도 응답을 고치지 않고 그대로 가져왔습니다.

③ 결과 3 · A를 최대 세 차례 돌리면

결론: 자가개선 루프는 효과가 없습니다. 예방 규칙 9개 중 다단계의 1개만 validation 30묶음에서 채택 기준을 넘었고, 그 규칙도 어떤 결정에도 쓰지 않은 held-out 30묶음에서는 같은 기준(하한 > 0)을 넘지 못했습니다.

이 쪽은 별도 실험입니다. 처음 실험의 validation 2묶음 측정은 버리고, 바뀐 v12 근거에서 주제마다 train 6 · validation 30 · held-out 30묶음을 새로 골라 A만 다시 돌렸습니다(실험 id `a30v12`, 2026-10-19). 다단계·표 값은 리뷰에서 고친 검사로 같은 묶음을 다시 잰 결과입니다(`a30v12f`). 4–5쪽의 A1·B·C와는 묶음이 다릅니다.



○ 1차 시도 ● 3차까지 전체 '모두 통과'는 열린 묶음이 남지 않아 일찍 멈췄다는 뜻입니다 (`no_open_bundles`).

커버리지
24 → 31
/42 묶음, +7 · 묶음별 재시도로 얻음

채택된 예방 규칙
1 / 9
다단계 multi_hop 아님 · 하한 +0.033

held-out 효과
19 → 21
/30 · 하한 −0.133, 기준 미달

비용
5.37
USD · 호출 1,441회 · 보고한 일곱 주제 합

예방 규칙 채택 시험: 9개 중 1개 채택, held-out에서 확인 안 됨

고정한 validation 30묶음에서 후보 규칙을 붙인 프롬프트와 붙이지 않은 프롬프트로 질문을 각각 만들고, 같은 묶음끼리 통과 여부를 견줘 그 차이의 평균(이득)을 냅니다. 이 차이를 1,000번 다시 뽑은 부트스트랩의 5백분위(하한)가 0보다 커야 채택합니다. 묶음 하나가 이득 0.033입니다.

주제	차수	시험한 규칙	이득	하한
수치	2차	조건·예외 누락	+0.033	−0.067
표	2차	표 관계	−0.133	−0.233
표	3차	출력 형식	−0.067	−0.167
비교	2차	복사형	−0.033	−0.200
다단계	2차	**multi_hop 아님 · 채택**	**+0.200**	**+0.033**

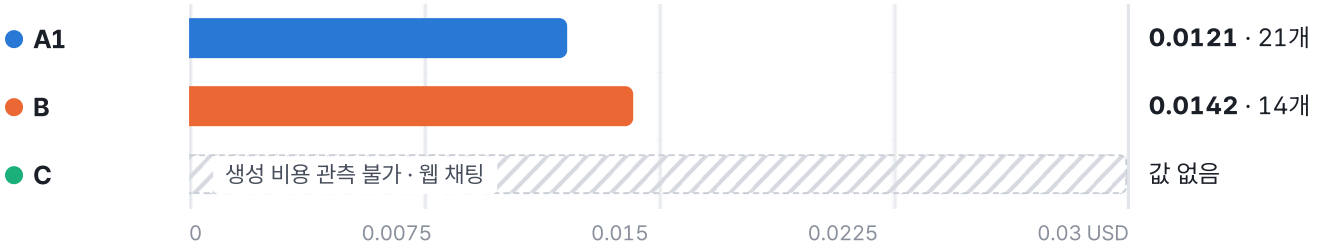
주제	차수	시험한 규칙	이득	하한
답 없음	2차	대상 문서에 있음	−0.033	−0.167
답 없음	3차	유형 불일치	+0.033	−0.133
틀린 전제	2차	유형 불일치	−0.033	−0.200
틀린 전제	3차	전제가 문서에 있음	−0.100	−0.267

채택된 다단계 규칙은 held-out 30묶음에서 21 대 19(이득 +0.067, 하한 −0.133)로 같은 기준을 넘지 못했습니다. 늘어난 7묶음은 거절된 묶음에 그 묶음의 실패 기록을 붙여 다시 만든 결과입니다(다단계 2·3차는 채택 규칙도 붙음). 표는 세 차례 모두 1/6이고 train 거절 15건 중 12건이 표 관계였지만 원인은 정하지 못했습니다. 출처는 각 실험의 `loops/a1` 입니다.

③ 결과 4 · 비용

gpt-5-mini 실제 장부 기준입니다. 첫 시도끼리는 유효 질문당 비용이 비슷합니다. A 반복 비용은 6쪽에 있습니다.

유효 질문 하나당 API 비용



주제별 (USD · 유효 질문당 USD)

주제	A1	B	C 검증만
수치	0.0229 · 0.0038	0.0163 · 0.0054	0.0247
표	0.0120 · 0.0040	0.0083 · 0.0042	0.0092
조건	0.0229 · 0.0076	0.0141 · 0.0141	0.0202
비교	0.0235 · 0.0118	0.0497 · 0.0166	0.0490
다단계	0.0516 · 0.0172	0.0295 · 0.0147	0.0858
답 없음	0.0773 · 값 없음	0.0612 · 값 없음	0.0216
틀린 전제	0.0438 · 0.0109	0.0195 · 0.0065	0.0172
전체	**0.2539 · 0.0121**	**0.1986 · 0.0142**	**0.2277**

비용에는 생성·검증·판정·다시 보낸 호출이 모두 들어갑니다. 유효 질문이 0개면 비율은 0이 아니라 값 없음입니다. C는 생성이 웹 채팅이라 생성 토큰·비용을 관측하지 못했고, 사람 처리 시간은 주제마다 약 3분, 전체 약 21분입니다(사용자 보고).

실험 장부 정산

정산 1.2173 USD · 상한의 41%

목표 2.40 · 상한 3.00

B 0.1986 + A 1–3차 0.7911 + C 검증 0.2277 · A 2·3차 결과는 버리고 지출만 남김

예약 = 정산	uncertain	run 기록과 차이	어림 vs 실제
355 = 355	**0건**	**0**	**1.23 / 1.22**
보내기 전 잡은 호출 전부 정산	청구 여부를 모르는 호출 없음	장부 합 = run 기록 합	승인 전 기댓값과 실제 정산

A 재측정 장부 (a30v12 · a30v12f, 2026-10-19 승인)

정산 3.9038 USD · 상한의 35%

어림 기댓값 4.76 · 상한 11.00

일곱 주제 A 1–3차 · 예약 1,053 = 정산 1,053 · uncertain 0건 · 같은 모델과 단가 · 최악 어림 10.51

다단계·표 재측정 `a30v12f` : 정산 2.7080 USD · 상한 3.50의 77% · 예약 758 = 정산 758 · uncertain 0건. 어림 1.25의 2.2배로, 채택된 규칙의 held-out 측정과 0행 청크 단독 검사가 호출을 늘렸습니다.

③ 결과 5 · 블라인드 검토 에이전트 판정

검증기가 통과시킨 것과 별개로, 출력이 정말 쓸 만한지 사람의 눈으로 보려던 검토입니다. 사용자가 이 검토를 에이전트에게 맡겼으므로, 아래 값은 사람이 확인한 품질이 아닙니다.

네 검사 (출력마다 Y · N)

`evidence_support`	인용 근거가 답을 받치는가
`answer_correct`	답이 맞는가
`topic_fit`	주제에 맞는 질문인가
`useful`	평가 문항으로 쓸모가 있는가

표본 뽑는 법

- 방식(A1·B·C) × 주제마다 첫 시도 출력 2개, 모두 42개
- 출력을 자동 검증 통과·거절·미판정으로 나누고, 이 순서로 한 분류에서 하나씩 뽑습니다. 분류 안에서는 고정 시드 20261018로 무작위로 고릅니다
- 검토지에는 주제·질문·답·인용 근거만 보이고, 생성 방식과 자동 검증 판정은 별도 대조표 (`review/key.json`)에만 있음

네 검사를 모두 통과한 비율

방식	전체	층: 검증 통과	층: 검증 거절
● A1	8/14	6/8	2/6
● B	5/14	3/7	2/7
● C	8/14	3/6	**5/8**

주제별 (각 2개 중 통과)

주제	A1	B	C
수치	●●	●●	●●
표	●○	○○	○○
조건	●○	●○	●●
비교	○○	○○	○○
다단계	●○	○○	●●
답 없음	●○	●○	○○
틀린 전제	●●	●○	●●

● 통과 ○ 하나 이상 N

읽을 때 주의할 것

- **표본은 거절 쪽으로 치우쳐 있습니다.** 거절된 출력이 있으면 표본에 반드시 하나 들어가므로, 위 비율은 전체 품질의 추정이 아닙니다.
- **C의 검증 거절 8개 중 5개가 네 검사를 통과했습니다.** 네 검사는 자동 검증기가 보는 주제별 필수 형식까지 검사하지 않으므로, 검증에서 유형 불일치로 거절된 출력도 여기서는 통과할 수 있습니다.
- **C는 완전히 가려지지 않았습니다.** 에이전트가 가져오기 때 C의 수치·표·답 없음 응답 일부를 이미 보았습니다.
- 에이전트는 대조표를 열지 않고 검토지만 보고 판정했습니다. 답 없음 두 항목은 대상 문서 원문을 검색해 확인했습니다.
- `evidence_support` 는 42개 모두 Y입니다. 실패는 주로 `useful` (개인 연락처·목차·형식 문구)과 `topic_fit` (억지 비교·억지 다단계)에서 나왔습니다.

④ 해석과 한계

이 표본(주제당 6묶음, 전체 42묶음)으로는 어느 방식이 확실히 낫다고 말할 수 없습니다. 보이는 것은 A1과 C가 B보다 낫다는 방향입니다.

말할 수 있는 것

- 첫 시도 커버리지는 A1 50% ≈ C 48% > B 33% 입니다.
- 주제 전용 프롬프트가 고정 프롬프트보다 나은 쪽입니다. 커버리지와 에이전트 판정 품질(8/14 대 5/14)이 같은 쪽을 가리킵니다.
- A의 자가개선 루프는 효과가 없습니다(별도 실험 `a30v12` · `a30v12f`). 예방 규칙 9개 중 1개만 validation 30묶음에서 채택됐고, held-out 30묶음에서는 같은 기준을 넘지 못했습니다.
- 이번 묶음에서 답 없음 주제는 세 방식 모두 첫 시도에 하나도 통과하지 못했습니다.
- 실험 비용은 승인한 상한의 41%(1.2173 USD)이고, 장부와 run 기록이 정확히 맞습니다.

말할 수 없는 것

- 어느 방식이 **확실히** 낫다는 결론. 주제마다 순서가 바뀌고, 한 묶음이 17%p입니다.
- C가 방식으로서 A1만큼 좋다는 것. 모델과 인터페이스가 함께 달랐습니다.
- C의 총비용과 유효 질문당 총비용. 생성 비용을 관측하지 못했습니다.
- A 재시도로 늘어난 6묶음 중 실패 기록 덕분인 몫. 실패 기록 없이 다시 만든 경우와 견주지 않았습니다.
- 사람이 본 품질. 검토는 에이전트가 했고, C는 완전히 가려지지 않았습니다.

결과를 흔드는 네 가지

요인	무엇이 문제인가	영향을 받는 결과
표본 크기	주제마다 train 6묶음. 묶음 하나가 17%p를 움직입니다.	주제별 순위 전부
C의 교란	C는 다른 모델(`gpt 6 pro` 표시)과 다른 인터페이스(웹 채팅, 한 메시지에 6묶음)를 썼습니다. 방식의 차이와 모델·인터페이스의 차이가 섞였습니다.	C 대 A·B 비교, C의 '독립 답과 다름'
A 재측정의 묶음	A 반복은 v12 근거에서 새로 고른 묶음으로 다시 쟀습니다. 4–5쪽의 비교와 묶음이 달라 두 결과의 커버리지를 섞을 수 없습니다.	6쪽과 4–5쪽을 잇는 해석
검토 주체	품질은 에이전트가 판정했고, 표본은 거절 쪽으로 치우쳐 있습니다.	검토한 품질 전부

이 결과가 남긴 질문

답 없음

왜 세 방식 모두 0/6인가

거절은 대부분 '대상 문서에 있음'이고, 세 방식에서 5·5·6건입니다. 주제 설계, 묶음 고르기, 생성 방식 중 어디가 원인인지는 이번 결과로 나눌 수 없습니다.

C

방식만의 효과는 얼마인가

생성 방식만의 효과를 보려면 모델과 인터페이스를 모두 A·B와 같게 맞춰야 합니다. 두 요인의 영향을 따로 보려면 한 번에 한 요인만 바꾸는 비교가 더 필요합니다.

표

표 주제는 왜 1/6에 머물렀나

v12 근거는 행이 있는 청크를 모두 표로 셉니다. 그래서 장 제목 상자와 흐름도도 표 묶음에 들어왔습니다. 데이터 표만 고르면 나아지는지가 다음에 확인할 가설입니다.

부록 A · 실험을 고정한 방법

결과가 같은 조건에서 나왔다는 것을 보증하는 장치입니다. 본문을 읽는 데는 필요 없고, 결과를 다시 내거나 의심할 때 봅니다.

근거 묶음 고정 (freeze)

- 주제마다 묶음 30개를 기존 규칙으로 고른 큰 계획(`abc7-pool`)에서, 차례대로 train 6 · validation 2 · held-out 2를 층화해 고릅니다.
- 몫은 자기 개선과 같은 해시 나눔이라, A의 loop가 실제로 쓰는 몫과 같습니다. 몫이 하나라도 모자라면 계획을 쓰지 않고 멈춥니다. 일곱 주제 모두 6 · 2 · 2를 채웠습니다.
- `compare` 와 검토지 생성은 계획·주제 명세·프롬프트가 고정 기록과 다르거나, 출력이 train 밖 묶음을 가리키면 멈춥니다. A·B의 생성 설정과 세 방식의 검증 설정도 서로 같아야 하며, 호출 한도와 예산은 이 비교에서 뺍니다.

고정한 것	SHA-256
v11 근거 manifest	`34905d57…c539`
큰 계획 abc7-pool	`ccbabaca…82c9`
실험 계획 abc7	`8e8f5dd5…0b52`
B · C 프롬프트	`587776a3` · `ce1ef8e1`
검증기 · 판정기	`ed21685b` · `a5b78950`

실험 장부: 상한을 넘는 호출은 보내지 않습니다

run마다 걸린 예산은 호출 묶음 사이에서만 검사하므로, 함께 날아가는 호출이나 끊긴 호출의 비용은 막지 못합니다. 그래서 이 실험의 모든 API 호출은 하나의 장부를 거쳤습니다.

보내기 전
최악 비용 예약
입력 UTF-8 바이트 + 메시지당 16, 출력은 출력 상한(20,000 토큰). 확정 비용에 더해 상한을 넘으면 보내지 않습니다.

→

응답 후
실제 토큰으로 정산
캐시 할인은 빼고 모두 입력 단가로 셉니다. SDK 안의 자동 재시도는 끕니다(장부가 모르는 재전송 방지).

→

오류 때
청구 여부로 나눔
429는 예약을 풀고 다시 보냅니다. 연결 오류·시간 초과·5xx는 청구됐을 수 있어 예약을 남기고(`uncertain`) 새로 잡습니다.

승인한 값 (2026-10-18)

모델 · 추론	gpt-5-mini · 생성 low · 검증기와 판정기 high
단가	입력 0.25 · 출력 2.00 USD / 100만 토큰 (2026-10-18 공식 가격표 Standard)
상한	실험 3.00 USD (목표 2.40 + 예비 0.60) · 명령별 한도 합 1,152 호출 · 2.16 USD · 호출마다 출력 20,000 토큰
어림 → 실제	● A 0.78 → 0.7911 · ● B 0.25 → 0.1986 · ● C 검증 0.19 → 0.2277 · **합계 1.23 → 1.2173**
비용에 넣지 않은 것	C를 만드는 데 쓴 기존 Pro 구독

C (Pro) 진행 규칙

주제마다 새 채팅을 열고 메모리·맞춤 지침·웹 검색·파일·도구를 끕니다. 주제 프롬프트 전체를 한 메시지로 붙여 넣고, 다른 글이나 A·B의 답은 넣지 않습니다. 첫 응답을 다시 생성하거나 고치지 않고, 응답 전체와 JSON 줄을 그대로 저장합니다. 형식이 어긋나도 고치지 않으며, 빠진 묶음이나 계획에 없는 줄은 거절 행으로 남습니다. 관측 기록(sidecar)은 돌아오지 않아 모델 표시 이름은 사용자 보고(`gpt 6 pro`)로만 남았고, 대응하는 API 모델은 추정하지 않았습니다.

부록 B · 검증 순서

후보마다 아래 순서로 보고 처음 걸린 곳에서 멈춥니다. 본문의 거절 이유는 이 표의 '걸리면' 칸입니다.

순서	검사	걸리면
1	주제 구조 검사(생성 때와 같은 검사)와 규칙 검사(모호한 대상, 끊긴 질문, 빈 칸 표, 답 덧붙임, 근거 지칭, 배점 기준 등)	유형 불일치 · 규칙별 이유
2	주제별 무료 검사: 표의 행·열 칸 값, 조건 문구, 답 없음의 핵심어가 묻는 문서에 없음, 틀린 전제의 수치가 문서에 없음	표 관계 · 조건·예외 누락 · 대상 문서에 있음 · 전제가 문서에 있음
3	같은 주제·방식에서 이미 통과한 항목과 근거 묶음이나 질문이 같음	중복
4–6	검증기 출력이 정해진 형식에 맞고(어기면 한 번 다시 부름), 근거 충돌을 알리지 않고, 근거만으로 답할 수 있음	검증기 출력 오류 · 근거 충돌 · 근거로 답할 수 없음
4–6′	답 없음만: 4–6 대신 묻는 문서 전체를 나눠 검증기에 줌. 검증기가 어느 부분에서도 답하지 못하고 근거 충돌도 없으면 통과. 검증은 여기서 끝나고 7–10은 건너뜀	대상 문서에 있음 · 근거 충돌 · 검증기 출력 오류
7	수치·틀린 전제: 독립 답에 수·단위가 있고 후보의 값·단위가 독립 답에 있음	유형 불일치 · 독립 답과 다름
8	질문에 독립 답이 이미 들어 있지 않음. 비교 질문이 선택지로 든 대상 이름 하나를 답하는 경우는 예외	복사형
9	독립 답과 후보 답이 같음(정규화, 정하지 못하면 판정기). 독립 답의 조건이 후보 답에 없으면 판정기가 그 조건이 답을 제한하는지 판단	독립 답과 다름 · 조건·예외 누락
10	다단계: 근거를 하나씩만 준 검증기 답이 어느 것도 독립 답과 같지 않음	multi_hop 아님