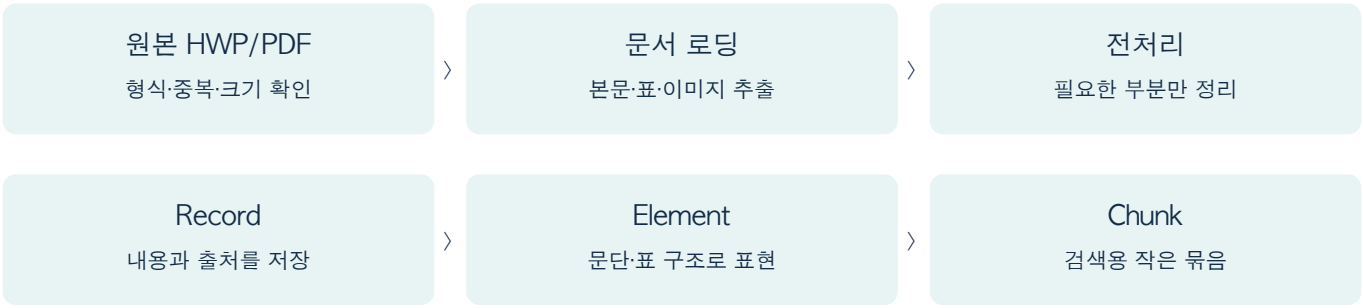
이 보고서의 범위: 문서를 읽고 청킹까지 준비하기

복잡한 RAG 전체 구조보다, 실제 EDA·전처리 작업이 어떻게 이어졌는지 보여준다.

작업의 출발점은 “문서 안에 어떤 정보가 있고, 어떤 방식으로 추출해야 뜻이 유지될까?”라는 질문이었다. 먼저 원본을 살펴보고, 추출 결과에서 문제를 찾은 뒤 정제·구조화 방식을 선택했다. 아래는 그 작업의 흐름이다.

그림 1. 원본을 읽고 검색에 쓸 단위로 정리하는 과정



각 단계에서 실제로 확인한 것

단계	쉽게 설명하면	작업의 목적
원본 EDA	파일을 열기 전에 형식·개수·중복·크기를 살펴봄	HWP에 집중할 이유와 중복 제외 기준을 정함
추출 결과 확인	본문과 표가 겹치는지, 이미지가 저장됐는지 확인	도구 실행 성공과 내용 추출 성공을 구분
텍스트 정제	한자·기호·목차·깨진 문자를 문맥에 맞게 처리	검색 편의를 높이면서 원문의 뜻을 지킴
구조·소속 연결	표와 문단, 요구사항 번호와 원본 위치를 연결	나중에 근거가 어디서 왔는지 추적
청킹·팀 전달	작은 묶음으로 나눈 결과를 살펴보고 v12를 공유	팀이 검색에 사용할 데이터 입력을 준비

용어는 이 세 가지로 이해하면 된다

Record는 “내용과 출처를 담은 정보 구간”, Element는 “문단·표처럼 구조를 구분한 요소”, Chunk는 “검색할 때 사용하는 작은 텍스트 묶음”이다. 예를 들어 로그인 요구사항 구간을 저장하고, 그 안의 표를 구조로 표현한 뒤 ID·설명·조건을 함께 검색하도록 나눈다.

내가 수행한 분석과 팀원이 구현한 코드를 구분

전처리 작업에서는 원본 EDA, 추출 품질 확인, 정제와 출처 연결, 청킹 비교를 수행했다. 실제 청킹 알고리즘은 Retriever 담당 팀원이 구현한 코드를 재사용했다. 노트북의 별도 비교 함수는 분할 특성을 살펴보는 실험용이다. 이 보고서는 청킹과 공유 데이터 전달까지 설명하며 이후 검색·답변 생성 성능을 측정한 결과로 확대하지 않는다.

이 결과가 의미하는 것: 핵심은 복잡한 시스템 구성을 많이 설명하는 것이 아니라, 데이터를 왜 그렇게 읽고 정리했는지와 어디까지 확인했는지를 보여주는 것이다.

RFP 문서 EDA와 전처리 의사결정

최종 기준: 실제 공유한 RFP_v12_Retriever_Package.zip | 원본·대표 실험은 별도 범위로 표시

RFP(제안요청서)는 사업의 기능·일정·조건을 정리한 문서다. RAG는 질문에 맞는 자료를 찾고 그 근거로 답변하는 방식이다. 이 보고서는 실제 팀 공유 v12를 기준으로, 왜 해당 전처리를 선택했고 무엇을 확인했는지 설명한다. 원본·대표문서 EDA와 후속 청킹 비교는 별도 실험으로 표시한다. 공유하지 않은 개선 데이터와 후보 결과는 프로젝트 성과에 포함하지 않는다.

그림 2. 원본 형식과 중복 처리



원본 100개(HWP96·PDF4)에서 완전히 같은 파일 2쌍을 확인했다. SHA-256(파일 내용 식별값)으로 묶은 뒤 전체 바이트도 비교했다. BioIN·한국보건산업진흥원의 의료기기산업 종합정보시스템 문서 쌍은 각827,392 bytes, 국가과학기술지식정보서비스·한국한의학연구원의 통합정보시스템 고도화 문서 쌍은 각868,864 bytes로 파일 전체가100% 일치했다. 대표 하나씩만 처리해 98개(HWP94·PDF4)를 사용하고 원본은 보존했다.

표 | 파일 크기 분포: 큰 파일 일부가 평균을 높인다

98개 원본 대표 파일	크기(KB)	해석
평균 / 중앙값	1,684.98 / 950.25	일부 큰 문서의 영향으로 평균이 더 큼
최소 / 최대	143.50 / 23,546.00	최대는 KOICA 관련 HWP; 상위10개는 HWP9·PDF1
HWP94개 평균 / 중앙값	1,618.00 / 943.75	대부분을 차지하므로 HWP 추출에 우선 집중
PDF4개 평균 / 중앙값	3,259.09 / 2,659.70	표본4개이므로 형식 전체의 일반 특성으로 확대 불가

이 결과가 의미하는 것: 파일 크기는 이미지·표에도 영향을 받는다. 큰 파일을 곧바로 긴 텍스트나 어려운 문서로 판단하지 않고, 추출 후 실제 분량·구조와 함께 살펴봐야 한다.

표 | 문서별 정제문 길이: 자료마다 분량이 다르다

분석 범위	최소 / 중앙값 / 최대	평균
98개 문서의 일반 Record clean_text 합산	48,751 / 75,123.5 / 284,853자	85,442.6자

이 결과가 의미하는 것: 문서별 분량 차이가 크면 큰 문서가 검색 자료에서 차지하는 비중도 커질 수 있다. 단, 이것은 정제문 합산 길이이며 원본 전체 문자 수나 실제 검색 편중을 측정한 값은 아니다.

출처: 원본 EDA §2. 길이 통계는 공유 ZIP v12의 clean_text를 문서별 합산해 재집계했다. 원본 전체 문자 수와 다르며 문서 간 중복 내용이 모두 제거됐다는 뜻도 아니다.

본문과 표를 따로 확인한 이유

RFP_EDA.pdf의 HWP 분석을 쉽게 풀어 설명 | 대표 HWP 문서 실험

문제: 일반 문장만 읽으면 표의 관계를 놓칠 수 있다

RFP는 요구사항 번호, 명칭, 상세 설명을 표 안에 넣는 경우가 많다. 글자만 꺼내면 “어떤 조건이 어떤 요구사항의 설명인가”가 흐려질 수 있다. 원본의 대부분이 HWP였기 때문에 HWP에서 본문과 표가 어떻게 추출되는지 먼저 살펴봤다.

선택과 이유: HwpHwpxLoader로 요소별 추출

기존 프로젝트의 HwpHwpxLoader를 사용했다. 본문과 표를 따로 확인할 수 있도록 elements 모드와 표 추출을 켰고, 표는 Markdown(문자로 읽기 쉽게 표현한 표)으로 표시했다. 선택의 이유는 추출 내용을 사람이 검토하기 쉬웠기 때문이다. 다른 파서보다 성능이 높다는 비교 실험을 한 것은 아니다.

원본 표
번호 | 명칭 | 설명
〉
요소별 추출
본문과 별도 표 확인
〉
대조
중복·누락·구조 차이 확인

발견: 같은 표 내용이 본문에도 들어 있었다

대표문서의 비교 기준	결과	읽는 방법
원문 표 문자열이 Body에 포함	213 / 226개 (94.25%)	별도 표의 대부분이 본문에도 나타남
공백·표 기호를 맞춘 뒤 포함	225 / 226개 (99.56%)	공백·구분 표시만 달라 불일치할 수 있음
남은1개 직접 확인	〔IMAGE〕 표시와 빈 셀 차이	주요 글은 양쪽에 있었음

이 결과가 의미하는 것: 표가 본문에도 있다고 본문과 표를 그대로 합치면 같은 정보가 반복된다. 반대로 표를 모두 지우면 행·열 관계를 잃을 수 있다. 따라서 “중복처럼 보이는가”와 “구조가 같은가”를 별도로 판단해야 했다.

조치와 한계

본문과 표를 단순 병합하거나 일괄 삭제하지 않고, 실제 내용과 원본 위치·셀 구조를 대조하는 방향을 택했다. 표를 별도 요소로 관리하고 원본 근거가 확인된 셀·병합 정보를 보완하는 이유도 여기에 있다.

94.25%와99.56%는 이 대표문서의 표 문자열 포함률이다. 전체98개 문서의 중복률이나 표 구조가 완전히 보존됐다는 비율은 아니다. Markdown은 보기 좋은 표현이지만 원본 셀의 물리 구조를 완전히 대신하지는 못한다.

출처: RFP_EDA.pdf §02, 전처리 EDA 노트북 §3. 대표문서 관찰과 공유 v12 전체 검증을 구분했다.

그림 안의 글자도 근거가 될 수 있을까?

OCR은 이미지 속 글자를 텍스트로 읽는 기술이다. 추출량과 정확성은 구분한다.

문제와 조치: 이미지 표시만 있고 파일은 없었다

처음에는 본문에 〔IMAGE〕 표시가 있어도 실제 이미지가 저장되지 않았다. 그림 안에 화면 설명이나 평가표가 있다면 텍스트만으로 내용을 파악하기 어렵다. 이미지 추출 옵션을 보완해 대표 HWP의 이미지9개를 저장하고 직접 살펴봤다.

대표 이미지의 구성	선택한 이유
화면5·일반2·혼합1·인쇄문서1개	로고·장식은 제외하고, 화면·평가표·문서처럼 정보가 있는7개를 OCR 대상으로 선정

선택: 동일 이미지에 EasyOCR과 Vision을 비교

어떤 방식이 글을 더 잘 읽는지 알아보기 위해 같은 이미지로 비교했다. EasyOCR은91개 영역에서1,017자, macOS Vision은73개 영역에서962자를 읽었다. 하지만 더 많이 읽었다는 것이 더 정확하다는 뜻은 아니므로 세 문구를 원본과 대조했다.

원본과 비교한 문구	EasyOCR 유사도	Vision 유사도
스톡옵션 관련 문구	76.92%	70.27%
주요 기능 관련 문구	92.31%	96.15%
사업 분야 관련 문구	73.33%	94.12%

이 결과가 의미하는 것: 세 문구 중 두 문구는 Vision, 한 문구는 EasyOCR의 유사도가 높았다. 어느 엔진이 모든 이미지에서 더 정확하다고 결정할 수는 없었다.

왜 한 가지 엔진으로 바로 확정하지 않았는가

두 엔진 모두 글자와 공백 오류가 있었다. EasyOCR에서는 신뢰도0.7 미만인 영역이 31/91개(34.1%)였다. 신뢰도는 엔진의 확신 정도이지 실제 정답률이 아니다. 작은 글씨·손글씨·중요 요구사항은 원본을 다시 확인해야 했다.

Vision은 macOS 전용이어서 비교용으로 사용했다. 팀은 macOS와 Windows를 함께 사용하므로 EasyOCR을 공통 환경의 후보로 두었다. 최종 OCR 엔진은 미확정이며, 운영체제 호환성과 정확성 검증을 함께 고려한 판단이다.

실제 사용 원칙

이미지와 원본 출처를 함께 저장하고, 대조해 확인한 텍스트 범위만 검색에 반영한다. 부분만 확인한 이미지를 전체가 정확한 이미지로 처리하지 않는다. 이번 세 문구의 문자열 유사도는 전체 OCR 정확도가 아니다.

출처: RFP_EDA.pdf §03, 전처리 EDA 노트북 §3. 이미지9개와 대상7개는 대표문서 실험이며 공유본 모든 이미지의 실행·검증 완료를 뜻하지 않는다.

무조건 지우는 대신 의미와 검색 편의를 나누다

RFP_EDA.pdf의 문자 처리 선택과 이유 | 대표 HWP Body 분석

문제: 정상 한자와 깨진 문자가 함께 있었다

문서에는 內·中처럼 뜻이 있는 한자와, 추출 과정에서 깨진 것으로 의심되는 문자가 섞여 있었다. 한자를 모두 지우면 뜻을 잃고, 모두 한글로 바꾸면 잘못 읽은 글자를 검색 데이터에 넣을 수 있다. 그래서 사용 문맥과 원본을 보고 구분했다.

대표 Body의 한자	관찰 결과	해석
전체	10종·48회	문자의 종류 수와 등장 횟수는 다른 단위
기존 독음 사전 등록	41회 (85.42%)	검토된 읽는 소리를 적용할 수 있는 범위
미등록	7회 (14.58%)	임의로 읽거나 삭제하지 않고 확인 대상으로 유지

선택과 이유: 원문은 남기고 검색에만 독음 추가

원문 內 과업 〉 검색용 표현 內(내) 과업 〉 목적 원문 보존 + 검색 편의

검토한 22자 사전으로 검색용 독음만 추가했다. 원문이 어떤 글자였는지 다시 확인할 수 있고, 정해진 범위 밖의 오변환을 제한하기 위한 선택이다. 사전 등록률85.42%는 변환 정확도가 아니며, hanja 라이브러리보다 우수하다는 비교 결과도 없다.

특수문자: 의미 있는 표시와 불필요한 표시를 구분

대표 Body에서 특수문자는 59종·13,380회 나왔다. 이 안에는 표·목록 구분과 조건·단위를 표현하는 기호도 있었다. 기호가 많다는 이유만으로 전부 지우지 않고, 의미 있는 기호는 보존했다. 불필요한 제어문자와 빈 표 행만 정리하고 깨진 문자는 원본 근거를 확인한 범위에서 복구했다.

이 결과가 의미하는 것: 이 대표 Body에서 제어문자 제거 대상은0개였다. 정제 규칙이 있다고 무조건 문자가 줄어야 하는 것은 아니다. 정상 내용을 건드리지 않았다는 관찰도 중요한 결과다.

왜 원문·정제문·검색문을 따로 저장했는가

raw_text는 추출한 원문, clean_text는 검증된 정리를 적용한 글, search_text는 검색 편의를 추가한 글이다. 원문을 보존하면서 필요한 수정만 추적하고, 독음처럼 원문에 없던 표현이 어디서 추가됐는지 구분하려는 설계다.

출처: RFP_EDA.pdf §04, 전처리 EDA 노트북 §4. 이 대표문서 실험을 공유 v12 전체 문자 처리의 정확성 인증으로 확대하지 않는다.

같은 번호가 반복돼도 같은 역할은 아니다

목차와 요구사항 ID의 용도를 보고 처리하고, 검색 근거의 소속을 관리했다.

목차: 버릴 내용과 지켜야 할 지침을 구분

본문을 찾아가는 탐색용 목차는 본문과 같은 제목을 반복하므로, 검증된 구간만 검색 입력에서 제외했다. 반면 "제안서에 무엇을 어떤 순서로 써야 하는가"를 알려주는 목차는 작성 지침이어서 보존했다. 겉모양이 목차라고 모두 지우지 않은 이유다.

확인 범위	결과	한계
PDF3개 문서	목차(toc) 요소56개	전체 PDF 목차 탐지 정확도를 뜻하지 않음
HWP	별도 toc 요소0개	목차가 없다는 뜻이 아니라 별도 분리 확인이 안 됨

요구사항 ID: 번호·내용·출처를 함께 관리

SFR-001 같은 요구사항 ID는 기능이나 조건을 가리키는 번호다. 정규식(정해진 글자 패턴을 찾는 규칙)으로 후보를 추출하고, 번호가 실제로 어느 요구사항에 속하는지 원본 위치와 함께 살폈다.

공유 v12의 재집계	결과	읽는 방법
ID 포함 Record / ID 등장	7,337개 / 7,438회	같은 번호도 목록·상세 설명에서 반복 가능
주요 유형	SFR1,339·PMR981·SER798회	기능·프로젝트 관리·보안 요구사항의 등장 분포

이 결과가 의미하는 것: 등장 횟수는 독립 요구사항 수나 연결 정확도가 아니다. 목록과 상세 설명의 반복을 지우면 근거가 사라질 수 있어 삭제보다 소속·출처를 연결하는 방법을 택했다.

최종 공유 v12에서는 무엇을 전달했는가

단위	공유 수치	관리하는 정보
Record	23,766개	내용 구간과 원본 출처
Element	26,045개	표14,030(53.87%), 문단11,935(45.83%), 목차56, 이미지 글24
Chunk	18,997개 (검색18,989)	팀의 검색 입력으로 사용하는 작은 근거 단위

표가 절반 이상이어서 표를 별도 관리하고, 원본 근거가 확인된 셀·병합 정보를 보완할 필요가 있었다. 공유 v12에서 소속키가 없는 Chunk는13,165개였지만 일반 설명·목차도 있으므로 모두 소속 오류로 판단하지 않는다.

출처: RFP_EDA.pdf §05~06, EDA 노트북 및 공유 v12 ZIP 재집계. 원본 EDA의 v13 소속 변경·검증 자식 수는9페이지에 미공유 참고로 따로 수록했다.

관련 설명을 함께 찾도록 어디에서 나눌까?

실제 팀 청커는 Retriever 담당 팀원이 구현했다. 전처리에서는 기존 코드 연계와 별도 비교실험을 진행했다.

그림 4. 분할 방식의 차이 — 이해를 위한 가상 예시이며 실험 원문이 아니다.

길이 기반	SFR-001 로그인 | 5회 실패하면	계정 잠금 | SFR-002 권한 관리 | 관리자만 설정
구조 기반	SFR-001 로그인 | 5회 실패하면 계정 잠금	SFR-002 권한 관리 | 관리자만 설정

길이 기준에서는 조건이 갈라질 수 있다. 구조 기준은 관련 내용을 묶되, 너무 길면 추가로 나눈다.

왜 두 방식을 비교했는가

일정 길이로 자르면 간단하지만 번호와 조건이 떨어질 수 있다. 구조를 따라 나누면 관련 내용을 묶기 쉽지만 짧은 묶음이 많아질 수 있다. 같은 대표문서에서 분할 결과가 어떻게 달라지는지 확인했다.

별도 비교용 구현·입력	길이 / 겹침	Chunk 수	여러 ID / ID포함 Chunk
Native PDF1699 Element · 길이	500자 / 50자	245	13 / 50
같은 Native · 구조	500자 / 0자	579	6 / 59
v12 대표413 Record · 길이	500자 / 50자	334	38 / 157 (24.20%)
같은 v12 · 구조	500자 / 0자	454	20 / 157 (12.74%)

ID 공동 출현은 하나의 묶음에 여러 요구사항 번호가 있는 경우다. 요약표나 상호참조일 수도 있어 오류율·검색 정확도는 아니다. 두 입력은 다른 대표문서이며 무작위 표본이나 버전 간 전후 비교도 아니다.

결과에서 알게 된 점과 멈춘 지점

구조 기반에서100자 미만 Chunk는 Native39.9%, v12는22.69%였다. 제목·본문 경로 조건을 추가한 개선형도 기존579개와 내용·순서가 같아 결과를 바꾸지 못했다. v12에서는 원래155종의 ID가 모두 남았지만 끝에서 숫자가 잘리며 각 방식에서1종이 추가 인식된 사례도 확인했다.

실제 팀 모듈도 같은 Native 입력에 별도로 실행해 구조 기반347개·고정창157개를 확인했다. 이 모듈은 토큰(모델의 글 처리 단위)을 사용하고 입력 표현·크기·겹침이 문자 비교군과 다르다. 따라서 비교용 알고리즘 결과와 운영 팀 코드 결과를 섞지 않았다.

이 결과가 의미하는 것: 이번에 확인한 것은 분할 특성과 일부 전달·인식 문제다. 구조 기반이 검색 성능에서 더 좋다고 입증한 것은 아니다. 다음에는 입력·크기·겹침을 통제하고 질문과 정답 근거로 검색 평가가 필요하다.

출처: 청킹 비교실험 노트북 §5~10. Native는 추출 요소, v12는 공유본과 같은 해시의 Record 입력이다. 실제 팀 모듈의 v12 대표 재실행은 없다. 표175개의 정규화 글자 일치는 확인했지만 표 구조·소속 인증은 아니다.

원문 보존 확인율 71.28%, 미인증 28.72%

기준: 실제 팀 공유 ZIP의 dataset/v12/manifest.json 및 preservation_audit.json

그림 5. 비공백 원문 단위의 보존 근거 확인 상태



공유 v12 감사 상태	원문 단위 수	확인율·뜻
PASS	217,866	71.279335%: 해당 기준의 보존 근거 확인
UNVERIFIED	87,785	28.720665%: 추가 확인이 필요한 상태
합계	305,651	비공백 원문 단위; Record·Chunk 수와 다름

UNVERIFIED는 실제 정보 손실률이 아니다. 글자가 남아 있어도 정확한 발생 위치·표 구조·요구사항 소속·Chunk까지의 전달 근거가 부족하면 미인증이다. 이 값은 공유 v12에 기록된 원문 보존 감사 상태이며 새로운 원문 추출·전체 재인증 결과가 아니다.

이 결과가 의미하는 것: 원문100% 보존을 입증하지 못했지만87,785개가 전부 사라졌다고 볼 수 없다. 패키지 무결성 통과와 원문 전체 보존 인증은 다른 검사다.

표 | v12 감사의 추가 검토·OCR 범위

구분	감사에 기록된 결과	해석
선별 원문32개 검토	새 PASS0 / 보류32	선별 검토로 기존 원문 상태를 새로 올리지 않음
OCR 관련 기록	검증 OCR Record총18 / 새 검증 이미지 5 / 새 검색내용23단위	전사·영역·Record는 다른 단위. 전체 이미지 정확도 인증 아님
이미지 검토 한계	부분영역 이미지5 / 선택보류 이미지1 / OCR재실행0	저장된 검증 결과이며 이번 작성 중 새 OCR을 실행하지 않음

원문에서 Chunk까지 추적해야 하는 이유

같은 문장이 반복되면 문자열 일치만으로 어느 셀의 내용인지 알 수 없다. 중첩표(표 안의 표)는 바깥 셀과의 관계가 필요하다. 기호는 의미 있는 조건과 단위를 담을 수 있어 제거 전후를 확인해야 한다. ID가 등장해도 해당 설명의 실제 소속이라는 보장은 없다. 따라서 원본→Record→Element→Chunk를 출처·문자·구조·소속으로 함께 확인해야 한다.

검증 범위: 공유 ZIP의 3개 JSONL 개수·SHA-256과 명세를 대조했고 감사 coverage와 명세 source_coverage가 일치했다. 감사 기준선은 v11이며 기존 원문 상태를 유지한다. 참조 원장 validation/source_status_merged.csv 전체는 ZIP에 없어 원장 행별 재판정은 수행하지 않았다. OCR 전사를 원문 분모의 새 PASS로 합산하지 않았다.

목표 → 미달 원인 → 다음 프로젝트의 검증 설계

회고는 공유본 감사와 확인된 대표문서·청킹 실험을 바탕으로 작성했다.

목표와결과: 원문100% 보존 근거를 확인하려 했다

RFP의 금액·기간·예외 조건은 작은 누락에도 의미가 달라질 수 있다. 공유 v12 감사는 PASS217,866개(71.279335%), 미인증87,785개(약28.72%)로 전체 보존 검증 목표에 이르지 못했다. 미인증은 실제 손실률이 아니라 근거 확인이 부족한 상태다.

원인 → 개선 방향 → 배운 점

같은 문장이 여러 셀에 반복되면 문자열 일치만으로 발생 위치를 구분할 수 없다. 중첩표는 바깥 셀과의 관계, 기호는 의미, ID는 실제 소속을 함께 확인해야 한다. OCR의 높은 신뢰도나 제한된 문구 비교도 전체 정확성의 인증은 아니다.

다음에는 추출 단계부터 원문 위치·표 부모관계·문자 변환 대응을 저장하고, 틀린 위치·잘린 숫자·잘못된 소속이 검사에서 거부되는지 확인해야 한다. 데이터가 남는 것과 보존을 입증하는 것은 다르다. 공유 버전과 개인 후속 분석을 분리하고 미완료 범위를 명확히 남기는 것이 이번 검증의 핵심 학습이다.

참고 | EDA PDF의 미공유 v13 기록

아래는 RFP_EDA.pdf(2026.10.15, v13 기준)에 실린 내용을 빠짐없이 전달하기 위한 별도 참고다. 팀 공유 v12에 적용된 성과나 보존율로 해석하지 않는다.

EDA PDF 항목	v13 원문 기록과 해석
요구사항 소속 변경	v12→v13: ECR-001 연결Chunk46→47, DAR-04는7→8. 본문 유지·소속 정보만 수정; 전체 연결 정확도 인증 아님
데이터 구성	일반 Record23,766·검증용 자식46(일반 원문 통계 제외). Element26,045·Chunk18,997(검색18,989); 공유본과 개수가 같아도 같은 내용은 아님
원문 보존 기록	분모305,651 중 PASS218,764(71.57%), 미인증86,887(28.43%). 공유 v12의 71.279335%와 별개이며 실제 정보 보존율·손실률 아님
이미지 전사 검증	발생1,563건 중 전체 정확성 미검증1,545, 부분17, 검증 전사1; 검색 반영18건. 엔진 정확도나 전체 이미지 인증 아님

출처와 적용 범위

RFP_EDA.pdf: 원본·대표 실험은2·3~6페이지, v13 전용 기록은 위 참고 표로 분리.
RFP_v12_Retriever_Package.zip: 공유본3개 JSONL·manifest.json·preservation_audit.json 대조. 팀 결과는 이 버전 기준.
01_RFP 전처리 +EDA.ipynb 및 02_RFP_청킹_비교실험.ipynb: EDA·분할·진단 근거. 실제 팀 청커는 Retriever 담당 팀원 구현, 비교용 함수는 별도 실험 코드.

결론: 반복 입력을 막되 의미·표 구조·소속을 보존하고, 원문·이미지·HWP 목차·일부 표 구조·연결 관계를 추가 확인해야 한다. 미검증을 오류로 단정하지 않는다. 실제 검색 품질은 별도 평가가 필요하다.